

单位代码	10476
学 号	2308283080
分 类 号	TP18

河南师范大学

硕 士 学 位 论 文

硬件损伤条件下去蜂窝大规模 MIMO 系统性能研究

专业学位领域： 计算机技术

专业学位类别： 工学硕士

申 请 人： 李世龙

指 导 教 师： 周猛 教授

二〇二六年五月

Performance analysis of cell free massive MIMO system based on reinforcement learning under hardware impairment

A Dissertation Submitted to
the Graduate School of Henan Normal University
in Partial Fulfillment of the Requirements
for the Degree of
Master of Engineering

By

Shilong Li

Supervisor: Prof. Meng Zhou

May, 2026

摘要

本文...。(摘要是一篇具有独立性和完整性的短文，应概括而扼要地反映出本论文的主要内容。包括研究目的、研究方法、研究结果和结论等，特别要突出研究结果和结论。中文摘要力求语言精炼准确，硕士学位论文摘要建议 500~800 字，博士学位论文建议 1000~1200 字。摘要中不可出现参考文献、图、表、化学结构式、非公知公用的符号和术语。英文摘要与中文摘要的内容应一致。)

关键词: ***; ***; ***; ***; ***; ***; ***; ***

Abstract

abstractabstractabstractabstractabstr

Key Words: ***, ***, ***, ***, ***, ***, ***, ***

目 录

摘要	I
Abstract	III
插图索引	VII
表格索引	IX
主要符号对照表	XI
缩略语表	XIII
第一章 绪论	1
1.1 研究背景和意义	1
1.2 国内外研究现状及发展趋势	1
1.3 论文主要内容和结构安排	1
1.3.1 学校情况	2
第二章 标题标题标题标题标题标题	5
2.1 标题 1	5
2.1.1 子标题 1	5
2.1.2 子标题 2	5
2.2 标题 2	5
2.3 标题 3	5
2.4 本章小结	5
第三章 图神经网络辅助深度强化学习的非理想硬件去蜂窝大规模 MIMO 系统	7
3.1 引言	7
3.2 模型设计	8
3.2.1 信道估计	8
3.2.2 上行数据传输	11
3.2.3 可实现速率分析	12
3.3 上行和速率最大化	16
3.4 DMAGNN-AC 算法设计	17
3.4.1 DMAGNN-AC 组件	18
3.4.2 算法设计	19

3.5	MADQIN 算法设计	24
3.6	数值结果与分析	25
3.7	本章小结	31
第四章	非理想硬件条件下去蜂窝大规模 MIMO 系统的 URLLC 服务资源分配策略	33
4.1	引言	33
4.2	可实现 URLLC 速率	34
4.3	算法设计	34
4.3.1	用户节点特征建模	34
4.3.2	干扰边特征建模	36
4.3.3	图神经网络消息传递机制	37
4.3.4	基于 Actor-Critic 的功率控制决策	38
4.3.5	奖励函数设计	39
4.3.6	算法训练流程	40
4.3.7	算法复杂度分析	40
4.4	本章小结	41
第五章	标题标题标题标题标题标题	43
5.1	标题 1	43
5.2	标题 2	43
5.3	标题 3	43
5.4	本章小结	43
第六章	总结与展望	45
6.1	主要研究结论	45
6.2	不足与展望	45
参考文献		47
致 谢		51
攻读硕士学位期间发表的学术论文		53
攻读硕士学位期间参加的科研项目		55
独创性声明和关于论文使用授权的说明		57

插图索引

图 1-1 *****	1
图 1-2 *****	1
图 3-1 System model of CF-mMIMO with nonlinear PAs and low-resolution ADCs.	8
图 3-2 DMAGNN-AC 网络架构图。	18
图 3-3 Network architecture of MADQIN.	23
图 3-4 不同 AP 数量下的上行可达和速率, $K = 20$, $N = 20$ 。	27
图 3-5 全功率传输下, 不同 AP 和 UE 数量时单用户速率的累积分布函数 (CDF), $N = 4$, $b_m = 10$ 。	27
图 3-6 在多种影响因素存在时, 低分辨率 ADC 的比特位数对上行用户和速率的影响。	28
图 3-7 在多种影响因素存在时, 低分辨率 ADC 的比特位数对上行用户和速率的影响。	28
图 3-8 Comparing the uplink sum-rate in a CF-mMIMO system with nonlinear PAs and low-resolution ADCs versus the ideal hardware scenario, with $b_m = 10$	29
图 3-9 Rate comparison based on different hardware impairments, with $b_m = 10$, $K = 20$	29
图 3-10 对比了 DMAGNN-AC 算法与全功率传输策略、DDPG 算法的优化性能, $b_m = 10$, N $= 4$ 。	30
图 3-11 在总比特数保持恒定的前提下, 本文所提的 MADQIN 算法相比平均分配策略在性能 上有显著提升, $b_{\text{total}} = 135$, $M = 15$, $K = 5$ 。	30
图 3-12 DMAGNN-AC 算法的收敛性。	31
图 3-13 MADQIN 算法的收敛性。	31

表格索引

表 1-1	不同 DACs 位数的量化系数	3
表 3-1	System basic parameter settings.	25
表 3-2	Neural Network Parameter Settings.	26
表 4-1	算法超参数设置	40

主要符号对照表

x	标量 x
$\mathbf{x}$	列矢量 $\mathbf{x}$
$\mathbf{X}$	矩阵 $\mathbf{X}$

缩略语表

***	***** , *****
***	***** , *****
***	***** , *****

第一章 绪论

1.1 研究背景和意义



图 1-1 *****




图 1-2 *****

1.2 国内外研究现状及发展趋势

1.3 论文主要内容和结构安排

河南师范大学位于豫北名城新乡市，北依巍巍太行，南濒滔滔黄河，坐落在广袤的牧野大地、美丽的卫水之滨。学校是国家中西部高等教育振兴计划支持高校、国家“111计划”实施高校、河南省人民政府与教育部共建高校、教育部本科教学工作水平评估优秀学校和河南省特色骨干大学，河南省“双一流”创建高校，三度蝉联全国文明单位，入选第二届全国文明校园^[2]。

文献^[2]表明.....

1.3.1 学校情况

学校历史底蕴深厚，办学资源丰富¹。在百年的办学历程中，逐步熔铸了“厚德博学止于至善”的校训、“明德正学倡和出新”的校风、“修至学立世范启智慧益品行”的教风、“尚诚朴勤学问重团结养正气”的学风，积累和沉淀了“崇文明道尚诚守德抱朴求真”的师大精神，以校风淳、教风正、学风浓、教学水平高享誉省内外。学校占地面积 139.53 万平方米，建筑面积 110.01 万平方米，中外文纸质图书 326.18 余万册，电子图书 1045.89 余万册。建有全球唯一一家帕瓦罗蒂音乐艺术中心和河南省规模最大、种类最多的生物资源博物馆，办有附属中学、附属小学和幼儿园。

定理 1.1. 对于 XXXXXXXXXXXX，通过 XXXXXXXXXXXX 可以表示为

$$\hat{\mathbf{g}}_{mk} = \sqrt{\tau\rho_p}\mathbf{R}_{mk}\tilde{\mathbf{\Xi}}_{mk}\tilde{\mathbf{y}}_{mk,p}, \quad (1-1)$$

证明. 根据 XXXXXXXXXXXX □

学校学科门类齐全，培养体系完备。现有哲学、经济学、法学、教育学、文学、历史学、理学、工学、农学、管理学、艺术学等 11 大学科门类。设有 25 个学院（部），4 个书院，89 个本科专业，其中国家一流本科专业建设点 34 个，省级一流本科专业建设点 23 个；32 个硕士学位授权一级学科、21 个硕士专业学位类别，10 个博士学位授权一级学科、1 个博士专业学位类别，7 个博士后科研流动站，各类学生 7.5 万余人。拥有国家学科创新引智基地（“111 计划”）2 个、河南省特色骨干 A 类学科 4 个、河南省特需急需特色骨干学科（群）1 个、河南省一级重点学科 28 个，化学、工程学、材料科学、环境/生态学、植物与动物科学等 5 个学科持续进入 ESI 全球前 1%，化学、地球与环境科学、物理学等 3 个学科持续进入本领域自然指数内地高校百强学科榜单。

¹学校前身是始建于 1923 年的中州大学（原国立河南大学前身）理科和创建于 1951 年的平原师范学院，历经河南师范学院二院、河南第二师范学院、新乡师范学院等阶段，1985 年始称河南师范大学。

表 1-1 不同 DACs 位数的量化系数

b_m	1	2	3	4	5
α_m	0.6366	0.8825	0.96546	0.990503	0.997501

第二章 标题标题标题标题标题标题

第二章内容第二章内容第二章内容第二章内容第二章内容

2.1 标题 1

2.1.1 子标题 1

2.1.2 子标题 2

2.2 标题 2

2.3 标题 3

2.4 本章小结

第三章 图神经网络辅助深度强化学习的非理想硬件去蜂窝大规模 MIMO 系统

在去蜂窝大规模多输入多输出 (CF-mMIMO) 系统中, 通过密集部署大量接入点 (AP), 可实现无缝通信覆盖, 显著提升用户频谱效率 (SE) 与系统总容量。然而, 该方案的实际部署面临高昂的成本压力, 并不可避免地引入非理想硬件因素。针对上述挑战, 本文系统研究了在用户设备 (UE) 端采用非线性功率放大器 (PA) 及接入点端配置低分辨率模数转换器 (ADC) 条件下, 上行 CF-mMIMO 系统的可达速率性能。

具体而言, 本文推导了上行用户可达速率的闭式表达式, 系统分析了接入点数量、用户密度、接入点天线数及 ADC 分辨率等多重因素的影响。为有效抑制用户间干扰并提升系统和速率, 提出了一种基于图神经网络 (GNN) 辅助的演员 - 评论家 (DMAGNN-AC) 功率分配算法。该框架突破了深度强化学习在高维非结构化状态空间下的表征瓶颈, 并实现了具备物理可解释性的特征嵌入。与全功率发射方案相比, 所提功率分配策略可使系统速率提升近 1.5 倍。进一步地, 为缓解低分辨率 ADC 对速率的不利影响, 设计了多智能体深度 Q 集成网络 (MADQIN) 以优化 ADC 分辨率分配策略。仿真结果充分验证了所提方案的有效性。

3.1 引言

在 CF-mMIMO 系统中, 随着 AP 大规模部署, 硬件成本与功耗随天线数量线性增长。一方面, 采用低成本收发机替代高精度器件可有效降低系统成本, 但实际应用中此类方案易使射频 (RF) 链路暴露于各类硬件损伤下。另一方面, 低分辨率模数转换器 (ADC) 的应用为实现低成本、低功耗 CF-mMIMO 系统提供了可行路径, 但对信道建模与优化算法提出了更高要求。为缓解硬件损伤导致的性能退化, 通过优化功率分配以降低用户间干扰成为有效手段。传统优化算法如分数规划 (FP) 与加权最小均方误差 (WMMSE) 虽在理论上具备优异性能, 但其高昂的计算复杂度难以满足实际部署需求, 且难以全面适应实际通信场景下的硬件损伤与信道衰落。相比之下, 无模型机器学习方法, 尤其是深度强化学习 (DRL), 凭借较低的在线计算复杂度及无需先验训练数据集等优势, 成为当前研究热点。然而, 传统 DRL 难以有效捕捉用户间复杂干扰关系与空间相关性, 常导致优化效率受限。




图 3-1 System model of CF-mMIMO with nonlinear PAs and low-resolution ADCs.

为突破上述瓶颈，近年来相关研究引入图表示方法来建模多用户系统中的干扰关系与空间相关性。图神经网络（GNN）能够将原始信道状态信息（CSI）映射为低维图嵌入，显式保留用户间空间相关特征，从而为 DRL 提供更具表征能力的状态空间。同时，GNN 对动态图结构（如用户移动导致的拓扑时变）的处理能力与 DRL 的环境交互机制天然兼容，二者深度融合可显著提升系统的移动性管理与网络协同优化能力。基于此，本文提出一种高性价比、工程可实现的 CF-mMIMO 通信方案，充分挖掘系统性能潜力，并构建自适应网络优化框架，通过解耦功率分配问题，有效克服传统 DRL 在高维非结构化状态空间下的表征瓶颈。

3.2 模型设计

在本文中，我们考虑了一个如图 3-1 所示的上行链路 CF-mMIMO 系统，该系统由 MN -天线 AP 和 K 个单天线 UE 组成。所有 AP 均通过回程链路与中央处理单元（CPU）相连。该系统采用时分双工（TDD）协议进行数据传输。由于本文仅关注上行数据传输阶段，因此相干时间间隔被分为两个阶段：1）上行链路训练；2）上行数据传输。

3.2.1 信道估计

本节采用无相关瑞利衰落信道模型 [25]，第 m 个 AP 与第 k 个 UE 之间的信道增益表示为：

$$\mathbf{g}_{mk} = \beta_{mk}^{1/2} \mathbf{h}_{mk}, \quad (3-1)$$

它同时考虑了大规模衰落效应 β_{mk} 与小规模衰落效应 $\mathbf{h}_{mk}$ 。其中， β_{mk} 综合考虑了几何衰减与阴影衰落，并且假定其在相干时间内保持不变。 $\mathbf{h}_{mk}$ 的元素是具有瑞利分布包络的复高斯随机变量。设 τ_c 为相干间隔长度， τ_p 表示每个相干间隔的上行训练时间。受训练时长限制，本文采用 $\tau_p < K$ 的非正交导频，并将使用相同导频序列的 UE 集合定义为 $\mathbf{P}_k$ 。上行训练阶段， K 个用户同时向所有 AP 发送非正交导频序列，第 k 个 UE 的导频信号可以表示为 $\sqrt{\tau_p}\boldsymbol{\varphi}_k \in \mathbb{C}^{\tau_p \times 1}$ ，其中 $\|\boldsymbol{\varphi}_k\|^2 = 1$ 。

本文采用更为精细的硬件非线性确定性行为模型^[32]，旨在更准确地建模导致硬件损伤的主要因素。该模型能够以少量参数表征各类硬件损伤所产生的物理影响。它将硬件输入输出关系描述为^[33]：

$$x_{\text{out}} = \sum_{i=0}^{N_p} a_{2i+1} x_{\text{in}} |x_{\text{in}}|^{2i} \quad (3-2)$$

其中 a_{2i+1} 为模型复系数， $2N_p + 1$ 为非线性阶数。该模型综合考虑了功率放大器、本地振荡器、混频器以及其他硬件组件的非线性特性。需要特别注意的是，由于带外存在于偶次项，准无记忆多项式中仅包含奇次项以表示带内失真。此外，三次项即可捕捉射频放大器主要非线性来源^[34,35]，因此本文采用 $N_p=1$ 的三次多项式模型。已有研究表明三次多项式模型可有效逼近实际非线性特性^[36,37]。经功率放大器非线性作用后，第 k 个 UE 输出信号可表示为：

$$\phi_k = \underbrace{a_1 \sqrt{\tau_p}}_{\tilde{a}_1} \boldsymbol{\varphi}_k + \underbrace{a_3 \tau_p \sqrt{\tau_p}}_{\tilde{a}_3} \boldsymbol{\varphi}_k \|\boldsymbol{\varphi}_k\|^2, \quad (3-3)$$

其中 $\tilde{a}_1 \triangleq a_1 \sqrt{\tau_p}$ ， $\tilde{a}_3 \triangleq a_3 \tau_p \sqrt{\tau_p}$ 。第 m 个 AP 接收到的导频矩阵为：

$$\mathbf{Y}_{p,m} = \sqrt{\rho_p} \sum_{k=1}^K \mathbf{g}_{mk} \phi_k^H + \mathbf{W}_{p,m} = \sqrt{\rho_p} \sum_{k=1}^K (\tilde{a}_1 \mathbf{g}_{mk} \boldsymbol{\varphi}_k^H + \tilde{a}_3 \mathbf{g}_{mk} \boldsymbol{\varphi}_k^H \|\boldsymbol{\varphi}_k\|^2) + \mathbf{W}_{p,m}, \quad (3-4)$$

其中 ρ_p 为导频信号归一化信噪比 (SNR)， $\mathbf{W}_{p,m} \in \mathbb{C}^{N \times \tau_p}$ 为第 m 个 AP 处加性高斯白噪声 (AWGN) 矩阵，其第 ς 列满足 $[\mathbf{W}_{p,m}]_{\varsigma} \sim \mathcal{CN}(\mathbf{0}, \mathbf{I}_N)$ 。为分析低分辨率 ADC 对系统性能的影响，本文采用非均匀量化器并引入加性量化噪声模型 (AQNM)，将量化过程引入的失真描述为一个高斯随机变量。已有研究验证该模型在中低信噪比下具有足够的

建模精度^[38,39]。结合式(3-4)，第 m 个 AP 处 ADC 的输出可表示为：

$$\tilde{\mathbf{Y}}_{p,m} \triangleq \alpha_m \mathbf{Y}_{p,m} + \tilde{\mathbf{W}}_{p,m} = \alpha_m \sqrt{\rho_p} \sum_{k=1}^K (\tilde{a}_1 \mathbf{g}_{mk} \boldsymbol{\varphi}_k^H + \tilde{a}_3 \mathbf{g}_{mk} \boldsymbol{\varphi}_k^H \|\boldsymbol{\varphi}_k\|^2) + \alpha_m \mathbf{W}_{p,m} + \tilde{\mathbf{W}}_{p,m}, \quad (3-5)$$

其中 α_m 由量化比特数 b_m 决定，表示第 m 个 AP 的 ADC 量化精度^[40]。 $\tilde{\mathbf{W}}_{p,m}$ 为加性高斯量化噪声，与 $\mathbf{Y}_{p,m}$ 互不相关，其协方差矩阵为：

$$\mathbf{R}_{\tilde{\mathbf{W}}_{p,m}} = \mathbb{E}\{\tilde{\mathbf{W}}_{p,m} \tilde{\mathbf{W}}_{p,m}^H\} = \alpha_m (1 - \alpha_m) \text{diag}(\mathbb{E}\{\mathbf{Y}_{p,m} \mathbf{Y}_{p,m}^H\}). \quad (3-6)$$

信号 $\tilde{\mathbf{Y}}_{p,m}$ 量化后投影至 $\boldsymbol{\varphi}_k$ 得：

$$\check{\mathbf{y}}_{p,mk} \triangleq \tilde{\mathbf{Y}}_{p,m} \boldsymbol{\varphi}_k = \alpha_m \sqrt{\rho_p} \sum_{k' \in \mathcal{P}_k} (\tilde{a}_1 + \tilde{a}_3 \tau_p) \mathbf{g}_{mk} + \alpha_m \mathbf{W}_{p,m} \boldsymbol{\varphi}_k + \tilde{\mathbf{W}}_{p,m} \boldsymbol{\varphi}_k. \quad (3-7)$$

据此可得如下引理：采用最小均方误差（MMSE）方法，信道向量 $\mathbf{g}_{mk}$ 的估计值为：

$$\hat{\mathbf{g}}_{mk} = c_{mk} \check{\mathbf{y}}_{p,mk}, \quad (3-8)$$

其中

$$c_{mk} = \mathbb{E}\{\mathbf{g}_{mk}^H \check{\mathbf{y}}_{p,mk}\} (\mathbb{E}\{\check{\mathbf{y}}_{p,mk}^H \check{\mathbf{y}}_{p,mk}\})^{-1} = \frac{\sqrt{\tau_p \rho_p} \beta_{mk} (a_1 + a_3 \tau_p)}{\tau_p \rho_p \sum_{k' \in \mathcal{P}_k} (a_1 + a_3 \tau_p)^2 \beta_{mk} + 1}. \quad (3-9)$$

信道估计第 n 个分量的均方值可以表示为：

$$\gamma_{mk} = \mathbb{E}\{|\hat{\mathbf{g}}_{mk}|^2\} = \frac{\tau_p \rho_p \alpha_m \beta_{mk}^2 (a_1 + a_3 \tau_p)^2}{\tau_p \rho_p \sum_{k' \in \mathcal{P}_k} (a_1 + a_3 \tau_p)^2 \beta_{mk} + 1}. \quad (3-10)$$

令 $\tilde{\mathbf{g}}_{mk} = \mathbf{g}_{mk} - \hat{\mathbf{g}}_{mk}$ 表示信道估计误差。根据 MMSE 估计性质， $\tilde{\mathbf{g}}_{mk}$ 与 $\hat{\mathbf{g}}_{mk}$ 相互独立且服从复高斯分布。因此，信道估计误差 $\tilde{\mathbf{g}}_{mk}$ 各元素均方误差满足 $[\tilde{\mathbf{g}}_{mk}]_n \sim \mathcal{CN}(0, \beta_{mk} - \gamma_{mk})$ 。

3.2.2 上行数据传输

在上行数据传输阶段，所有 UEs 同时向 APs 发送数据 q_k ，其满足 $\mathbb{E}\{|q_k|^2\} = 1, \forall k$ 。在 UE 侧 PA 的非线性作用后，第 k 个 UE 的输出信号为

$$y_k = \sqrt{\rho_u} \left(a_1 \sqrt{\eta_k} q_k + a_3 \sqrt{\eta_k} q_k |\sqrt{\eta_k} q_k|^2 \right) = \sqrt{\rho_u} \left(\tilde{a}_{1k} q_k + \tilde{a}_{3k} q_k |q_k|^2 \right), \quad (3-11)$$

其中， ρ_u 表示每个 UE 的最大归一化发射功率， $\tilde{a}_{1k} \triangleq a_1 \sqrt{\eta_k}$ ， $\tilde{a}_{3k} \triangleq a_3 \eta_k \sqrt{\eta_k}$ 。此外，功率控制系数 η_k ($\forall k$) 满足 $\mathbb{E}\{|y_k|^2\} \leq \rho_u$ 。因此，该约束可简化为

$$|a_1|^2 \eta_k + 2(a_1^* a_3 + a_1 a_3^*) \eta_k^2 + 6|a_3|^2 \eta_k^3 \leq 1, \forall k. \quad (3-12)$$

第 m 个 AP 接收到的复基带信号可表示为

$$\mathbf{y}_{u,m} = \sqrt{\rho_u} \sum_{k=1}^K (\tilde{a}_{1k} \mathbf{g}_{mk} q_k + \tilde{a}_{3k} \mathbf{g}_{mk} q_k |q_k|^2) + \mathbf{w}_{u,m}, \quad (3-13)$$

其中， $\mathbf{w}_{u,m} \sim \mathcal{CN}(\mathbf{0}, \mathbf{I}_N)$ 表示加性噪声。随后，第 m 个 AP 的接收信号经 ADC 量化，其量化输出可表示为：

$$\begin{aligned} \mathbf{y}_{u,m} &= \alpha_m \mathbf{y}_{u,m} + \mathbf{w}_{u,m} \\ &= \alpha_m \sqrt{\rho_u} \sum_{k=1}^K (\tilde{a}_{1k} \mathbf{g}_{mk} q_k + \tilde{a}_{3k} \mathbf{g}_{mk} q_k |q_k|^2) + \alpha_m \mathbf{w}_{u,m} + \mathbf{w}_{u,m}, \end{aligned} \quad (3-14)$$

其中， $\tilde{\mathbf{w}}_{u,m}$ 表示量化噪声，其协方差矩阵可表示为：

$$\mathbf{R}_{\tilde{\mathbf{w}}_{u,m}} \approx \alpha_m (1 - \alpha_m) \text{diag}(\mathbb{E}\{\mathbf{y}_{u,m} \mathbf{y}_{u,m}^H\}). \quad (3-15)$$

为检测 q_k ，每个 AP 采用分布式方式，通过低复杂度的匹配滤波器合并计算本地数据估计值，随后经前传链路将信号汇总至中央处理单元（CPU）进行聚合与译码。因此，

中央处理单元处的接收信号可表示为：

$$\begin{aligned}
 r_{u,k} &= \sum_{m=1}^M \mathbf{g}_{mk}^H \mathbf{y}_{u,m} \\
 &= \sqrt{\rho_u} \sum_{m=1}^M \alpha_m \sum_{k'=1}^K \mathbf{g}_{mk}^H \tilde{a}_{1k'} \mathbf{g}_{mk'} q_{k'} \\
 &\quad + \sqrt{\rho_u} \sum_{m=1}^M \alpha_m \sum_{k'=1}^K \mathbf{g}_{mk}^H \tilde{a}_{3k'} \mathbf{g}_{mk'} q_{k'} |q_{k'}|^2 + \sum_{m=1}^M \mathbf{g}_{mk}^H \alpha_m \mathbf{w}_{u,m} + \sum_{m=1}^M \mathbf{g}_{mk}^H \mathbf{w}_{u,m}. \quad (3-16)
 \end{aligned}$$

随后，基于 $r_{u,k}$ 检测 q_k 的值。在下一节中，我们将推导用户可达速率的封闭表达式。

3.2.3 可实现速率分析

本节在综合考虑非线性 PA 与低分辨率 ADC 影响的前提下，推导了 CF-mMIMO 系统中上行 UE 的可实现速率。由于每个 AP 仅能获得信道估计信息，CPU 无法获取实际的瞬时信道状态。假定 CPU 已知信道状态的统计均值，据此计算可实现速率^[37]。结合式(3-16)，可将 CPU 端的接收信号重新表示为

$$\begin{aligned}
 r_{u,k} &= \text{ES}_k \cdot q_k + \text{BU}_k \cdot q_k + \sum_{k' \neq k}^K \text{I}_{kk'} \cdot q_{k'} \\
 &\quad + \sum_{k' \neq k}^K \text{NB}_{kk'} \cdot q_{k'} + \text{N}_k + \text{Q}_k, \quad (3-17)
 \end{aligned}$$

式中， ES_k 、 BU_k 、 $\text{I}_{kk'}$ 、 $\text{NB}_{kk'}$ 、 N_k 和 Q_k 分别表示第 k 个 UE 的期望信号确定性分量、波束成形不确定性、第 k' 个用户设备产生的干扰、第 k 个用户设备功率放大器非线性引入的干扰、加性噪声以及量化噪声。我们首先计算预期信号 ES_k ，由于 $\mathbf{g}_{mk}$ 和 $\mathbf{g}_{mk}$ 相互独立，我们有

$$\begin{aligned}
 \mathbb{E} S_k &= \sqrt{\rho_u} \mathbb{E} \left\{ \sum_{m=1}^M \alpha_m (\tilde{a}_{1k} \mathbf{g}_{mk}^H \mathbf{g}_{mk} + \tilde{a}_{3k} \mathbf{g}_{mk}^H \mathbf{g}_{mk} |q_k|^2) \right\} \\
 &= \sqrt{\rho_u} \mathbb{E} \left\{ \sum_{m=1}^M \alpha_m \tilde{a}_{1k} \mathbf{g}_{mk}^H (\mathbf{g}_{mk} + \mathbf{g}_{mk}) \right\} + \sqrt{\rho_u} \mathbb{E} \left\{ \sum_{m=1}^M \alpha_m \tilde{a}_{3k} \mathbf{g}_{mk}^H (\mathbf{g}_{mk} + \mathbf{g}_{mk} |q_k|^2) \right\} \\
 &= \sqrt{\rho_u} \mathbb{E} \left\{ \sum_{m=1}^M \alpha_m (N \tilde{a}_{1k} \gamma_{mk} + N \tilde{a}_{3k} \gamma_{mk} |q_k|^2) \right\} \\
 &= N \sqrt{\rho_u} |\tilde{a}_{1k} + \tilde{a}_{3k}| \sum_{m=1}^M \alpha_m \gamma_{mk}. \tag{3-18}
 \end{aligned}$$

此外，加性噪声 N_k 的方差为

$$\mathbb{E} \{ |N_k|^2 \} = \sum_{m=1}^M \mathbb{E} \{ \alpha_m^2 \|\hat{\mathbf{g}}_{mk}\|^2 \} \mathbb{E} \{ \|\mathbf{w}_{u,m}\|^2 \} = N^2 \sum_{m=1}^M \alpha_m^2 \gamma_{mk}. \tag{3-19}$$

量化噪声的方差为：

$$\begin{aligned}
 \mathbb{E} \{ |Q_k|^2 \} &= \mathbb{E} \left\{ \left| \sum_{m=1}^M \mathbf{g}_{mk}^H \mathbf{w}_{u,m} \right|^2 \right\} \\
 &= N \sum_{m=1}^M \alpha_m (1 - \alpha_m) \mathbb{E} \{ \mathbf{y}_{u,m} \mathbf{y}_{u,m}^H \} \gamma_{mk} \\
 &= N \rho_u \sum_{m=1}^M \alpha_m (1 - \alpha_m) \left(\sum_{k=1}^K \beta_{mk} \Omega_k + 1 \right) \gamma_{mk}. \tag{3-20}
 \end{aligned}$$

为了便于公式的展开，我们将第 k 个 UE 的总干扰定义为 Θ_k ，将其他用户造成的干扰定义为 $\mathbf{U}_{kk'} \triangleq \mathbf{I}_{kk'} + \mathbf{N} \mathbf{B}_{kk'}$ 。因此，总干扰的方差可以表示为：

$$\begin{aligned}
 \mathbb{E} \{ |\Theta_k|^2 \} &= \mathbb{E} \left\{ |\mathbf{B} \mathbf{U}_k|^2 |q_k|^2 + \mathbf{B} \mathbf{U}_k^* q_k^* \sum_{l' \neq k}^K \mathbf{U}_{kl'} q_{l'} \right. \\
 &\quad \left. + \mathbb{E} \left\{ \mathbf{B} \mathbf{U}_k q_k \sum_{k' \neq k}^K \mathbf{U}_{kk'}^* q_{k'}^* + \sum_{k' l' \neq k}^K \mathbf{U}_{kk'}^* \mathbf{U}_{kl'} q_{k'}^* q_{l'} \right\} \right\}. \tag{3-21}
 \end{aligned}$$

接下来，我们分别计算(3-21)中各项的值。第一项的值被分解为：

$$\mathbb{E} \{ |\mathbf{B} \mathbf{U}_k|^2 |q_k|^2 \} \triangleq \mathbb{E} \{ \mathbf{B}_1 |q_k|^2 \} - \mathbb{E} \{ \mathbf{B}_2 |q_k|^2 \} - \mathbb{E} \{ \mathbf{B}_3 |q_k|^2 \} + \mathbb{E} \{ \mathbf{B}_4 |q_k|^2 \}, \tag{3-22}$$

其中

$$\begin{aligned} B_1 &= \rho_u \sum_{m=1}^M \alpha_m (\tilde{a}_{1k} \mathbf{g}_{mk} \mathbf{g}_{mk}^H + \tilde{a}_{3k} \mathbf{g}_{mk} \mathbf{g}_{mk}^H |q_k|^2) \times \sum_{n=1}^M \alpha_n (\tilde{a}_{1k} \mathbf{g}_{nk} \mathbf{g}_{nk}^H + \tilde{a}_{3k} \mathbf{g}_{nk} \mathbf{g}_{nk}^H |q_k|^2) \\ &= N^2 \rho_u \sum_{m=1}^M \Omega_{k'} \alpha_m^2 \gamma_{mk} \beta_{mk'}, \end{aligned} \quad (3-23)$$

$$\begin{aligned} B_2 &= \rho_u \sum_{m=1}^M \alpha_m (\tilde{a}_{1k} \mathbf{g}_{mk} \mathbf{g}_{mk}^H + \tilde{a}_{3k} \mathbf{g}_{mk} \mathbf{g}_{mk}^H |q_k|^2) \times \sum_{m=1}^M \alpha_m (\tilde{a}_{1k} \mathbf{g}_{mk} \mathbf{g}_{mk}^H + \tilde{a}_{3k} \mathbf{g}_{mk} \mathbf{g}_{mk}^H |q_k|^2) \\ &= N^2 \rho_u \sum_{m=1}^M \alpha_m^2 (\tilde{a}_{1k}^2 \gamma_{mk}^2 + 3\tilde{a}_{1k} \tilde{a}_{3k} \gamma_{mk}^2 + 2\tilde{a}_{3k}^2 \gamma_{mk}^2), \end{aligned} \quad (3-24)$$

$$B_3 = B_2^*, \quad (3-25)$$

$$B_4 = \rho_u \left| \mathbb{E} \left\{ \sum_{m=1}^M \alpha_m (\tilde{a}_{1k} \mathbf{g}_{mk} \mathbf{g}_{mk}^H + \tilde{a}_{3k} \mathbf{g}_{mk} \mathbf{g}_{mk}^H |q_k|^2) \right\} \right|^2 = N^2 \rho_u |\tilde{a}_{1k} + \tilde{a}_{3k}|^2 \sum_{m=1}^M \alpha_m^2 \gamma_{mk}^2. \quad (3-26)$$

原始数据 q_k 是一个具有圆对称特性的复高斯随机变量, 其满足 $\mathbb{E}\{|q_k|^2\} = 1$, $\mathbb{E}\{|q_k|^4\} = 2$, $\mathbb{E}\{|q_k|^6\} = 6$ 。当式(3-21)中第二项和第三项的 $k' \neq k$ 时, $q_{k'}$ 和 q_k 的积将导致

$$\mathbb{E} \left\{ \text{BU}_k^* q_k^* \sum_{l' \neq k}^K \text{UI}_{kl'} q_{l'} \right\} = \mathbb{E} \left\{ \text{BU}_k q_k \sum_{k' \neq k}^K \text{UI}_{kk'}^* q_{k'}^* \right\} = \mathbf{0}. \quad (3-27)$$

式(3-21)中的最后一项中, 令 $\text{UI}_{kk'}^H \text{UI}_{kl'} = \text{U}_1 + \text{U}_2 + \text{U}_3 + \text{U}_4$, 计算后结果如下所示:

$$\mathbb{E} \left\{ \sum_{k', l' \neq k}^K \text{U}_1 q_{k'}^* q_{l'} \right\} = N^2 \rho_u \sum_{k' \neq k}^K \sum_{m=1}^M \alpha_m^2 |\tilde{a}_{1k'}|^2 \gamma_{mk} \beta_{mk'}, \quad (3-28)$$

$$\mathbb{E} \left\{ \sum_{k', l' \neq k}^K \text{U}_2 q_{k'}^* q_{l'} \right\} = 2N^2 \rho_u \sum_{k' \neq k}^K \sum_{m=1}^M \alpha_m^2 \tilde{a}_{1k'}^* \tilde{a}_{3k'} \gamma_{mk} \beta_{mk'}, \quad (3-29)$$

$$\mathbb{E} \left\{ \sum_{k', l' \neq k}^K \text{U}_3 q_{k'}^* q_{l'} \right\} = 2N^2 \rho_u \sum_{m=1}^M \sum_{k' \neq k}^K \alpha_m^2 \tilde{a}_{1k'} \tilde{a}_{3k'}^* \gamma_{mk} \beta_{mk'}, \quad (3-30)$$

$$\mathbb{E} \left\{ \sum_{k', l' \neq k}^K \text{U}_4 q_{k'}^* q_{l'} \right\} = 6N^2 \rho_u \sum_{m=1}^M \sum_{k' \neq k}^K |\tilde{a}_{3k'}|^2 \alpha_m^2 \gamma_{mk} \beta_{mk'}. \quad (3-31)$$

结合式(3-28)-(3-31)，我们可以得到

$$\mathbb{E} \left\{ \sum_{k', l' \neq k}^k \mathbf{U} \mathbf{I}_{kk'}^* \mathbf{U} \mathbf{I}_{kl'} q_{k'}^* q_{l'} \right\} = N^2 \rho_u \sum_{m=1}^M \sum_{k' \neq k}^K \Omega_{k'} \alpha_m^2 \gamma_{mk} \beta_{mk'}. \quad (3-32)$$

将式(3-17)中干扰与噪声之和等效为有效噪声。在最坏情况下，将干扰项视为不相关高斯噪声随机变量，由此可得第 k 个 UE 的上行可达速率如式(3-33)所示。

定理 1：在具有协整波束成形（CB）的 CF-mMIMO 系统中，对于任意有限的 M 和 K ，第 k 个用户设备的可达速率由式(3-34)给出（见下页顶部）。

$$R_{u,k} = \log_2 \left(1 + \frac{|\mathbf{E} \mathbf{S}_k|^2}{\mathbb{E} \{ |\mathbf{B} \mathbf{U}_k|^2 \} + \sum_{k' \neq k}^K \mathbb{E} \{ |\mathbf{I}_{kk'}|^2 \} + \sum_{k' \neq k}^K \mathbb{E} \{ |\mathbf{N} \mathbf{B}_{kk'}|^2 \} + \mathbb{E} \{ |\mathbf{N}_k|^2 \} + \mathbb{E} \{ |\mathbf{Q}_k|^2 \} } \right). \quad (3-33)$$

$$R_{u,k} = \log_2 \left(1 + \frac{N^2 \rho_u |\tilde{a}_{1k} + \tilde{a}_{3k}|^2 \left(\sum_{m=1}^M \alpha_m \gamma_{mk} \right)^2}{N^2 \rho_u \sum_{k'=1}^K \left(\Omega_{k'} \sum_{m=1}^M \alpha_m^2 \gamma_{mk} \beta_{mk'} \right) + 3N^2 \rho_u |a_3|^2 \eta_k^3 \left(\sum_{m=1}^M \alpha_m^2 \gamma_{mk} \right)^2 + N^2 \sum_{m=1}^M \alpha_m^2 \gamma_{mk} + \Psi_k} \right). \quad (3-34)$$

where

$$\Omega_k = (|a_1|^2 \eta_k + 2a_1^* a_3 \eta_k^2 + 2a_1 a_3^* \eta_k^2 + 6|a_3|^2 \eta_k^3), \quad (3-35)$$

$$\Psi_k = N \rho_u \sum_{m=1}^M \alpha_m (1 - \alpha_m) \left(\sum_{k=1}^K \beta_{mk} \Omega_k + 1 \right) \gamma_{mk}. \quad (3-36)$$

基于式(3-34)，对配备非线性 PA 与低分辨率 ADC 的 CF-mMIMO 系统性能进行如下关键分析：

定理 1 给出了可实现速率的精确闭式表达式，清晰揭示了系统关键参数与性能之间的内在联系。具体而言，式 (23) 中的系数 a_3 刻画了功率放大器的非线性特性。随着 PA 非线性程度的增强， a_3 的绝对值增大，导致信噪加干扰比（SINR）分子减小、分母增大，从而使用户可实现速率显著下降，表明 PA 非线性对系统速率具有明显的负面影响。进一步分析可知，除量化噪声项外，表达式分子与分母其余各项均包含天线数 N 的平方因子。对分子与分母同除以 N^2 后，仅有 $\rho_u \sum_{m=1}^M \alpha_m (1 - \alpha_m) \left(\sum_{k=1}^K \beta_{mk} \Omega_k + 1 \right) \gamma_{mk} / N$ 与 N

相关。随着天线数 N 增大, 用户速率在初始阶段将获得提升; 当 N 相对于 $\rho_u \sum_{m=1}^M \alpha_m (1 - \alpha_m) \left(\sum_{k=1}^K \beta_{mk} \Omega_k + 1 \right) \gamma_{mk}$ 足够大时, 其对可实现速率的影响趋于饱和。

3.3 上行和速率最大化

在 CF-mMIMO 系统中, 由于各接入点 (AP) 会接收所有用户设备 (UE) 发送的信号, 用户间的相互干扰将显著影响目标用户的上行速率。因此, 合理调控各用户的发射功率, 平衡目标信号与干扰信号之间的关系, 对于提升系统整体性能具有重要意义。

基于上述背景及闭式解中的可调参数, 本文建立了上行功率控制优化模型。该模型以非负功率集合为约束, 目标在于最大化系统总速率, 并要求每个功率变量不超过预设的最大限值。依据式(3-34), 上行总速率最大化问题可表述为:

$$\mathcal{P}_1 : \max_{\{\eta_k\}} \sum_{k=1}^K R_{u,k} \quad (3-37)$$

$$\text{s.t. } |a_1|^2 \eta_k + 2(a_1^* a_3 + a_1 a_3^*) \eta_k^2 + 6|a_3|^2 \eta_k^3 \leq 1, \forall k. \quad (3-38)$$

通常情况下, 优化问题 $\mathcal{P}_1$ 属于非凸 NP 难问题。这一特性导致传统基于模型的方法难以精确量化其与最优解之间的性能差距, 且计算复杂度较高。此外, 基于模型的优化方法自适应能力有限, 难以灵活应对未来异构业务需求的多样性及无线环境的动态变化。值得注意的是, 信道状态信息 $\mathbf{g}_{mk}$ 是求解该问题的关键统计量, 蕴含了确定最优功率控制策略的重要信息。因此, $\mathbf{g}_{mk}$ 与功率控制系数 η_k 之间存在潜在的映射关系。针对上述挑战, 本文引入数据驱动的深度强化学习 (Deep Reinforcement Learning, DRL) 方法, 挖掘并实现该映射关系, 从而提升系统的自适应与优化能力。

进一步地, 基于式(3-34)的推导结果可知, 用户速率随 ADC 量化系数 α_m 的增大呈单调递增趋势。结合量化噪声项的影响, 可通过动态调整 ADC 量化比特数以实现系统总速率最大化。为此, 本文采用改进型深度 Q 学习算法作为优化工具, 以用户总速率最

大化为目标，将 ADC 量化精度分配问题形式化为：

$$\mathcal{P}_2 : \max_{\{b_m\}} \sum_{k=1}^K R_{u,k} \quad (3-39)$$

$$\text{s.t. } b_m = 0, 1, 2, \dots, \forall m, \quad (3-40)$$

$$N \sum_{m=1}^M b_m = B_{\max}, \quad (3-41)$$

其中， $B_{\max}$ 表示所有 AP 上 ADC 的总量化比特数约束。

综上，针对上述两类优化问题，本文将在后续章节分别设计相应的算法，对 CF-mMIMO 系统的性能进行深入分析与探讨。

3.4 DMAGNN-AC 算法设计

在深度强化学习（DRL）领域，马尔可夫决策过程（Markov Decision Process, MDP）是序贯决策问题建模的基础框架。MDP 中，智能体与环境交互，智能体依据策略函数 π 和当前状态 s 选择并执行动作 a ，环境以奖励 r 反馈动作优劣，并转移至下一状态 s' 。完整回合中，智能体多次决策，动作与状态转移共同构成元组 $(\mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R})$ ，其中 $\mathcal{S}$ 为状态空间， $\mathcal{A}$ 为动作空间， $\mathcal{P}$ 为状态转移概率函数， $\mathcal{R}$ 为奖励函数。

为实现基于深度强化学习的功率分配，本文将优化问题 $\mathcal{P}_1$ 建模为 MDP。然而，受限于用户间复杂干扰关系与空间相关性，传统 DRL 方法难以高效学习最优策略。针对该难题，本文提出动态多智能体图神经网络（DMAGNN）框架，专用于提取用户间干扰特征，提供结构化状态信息，显著提升 DRL 性能。在该框架中，CPU 作为智能体，环境由 UE 和 AP 等组成。DMAGNN 将用户与接入点间信道状态信息建模为节点特征，将用户间干扰建模为边。该神经网络的详细结构与流程如图 3-2 所示。




图 3-2 DMAGNN-AC 网络架构图。

3.4.1 DMAGNN-AC 组件

1) 状态设计：第三节已指出，第 k 个 UE 与第 m 个 AP 之间的信道状态信息 $\mathbf{g}_{mk}$ 与功率控制系数 η_k 存在映射关系。由于 CPU 无法获取信道的实时观测值，本文最终采用理论信道状态信息 $\mathbf{g}_{mk}$ 作为神经网络输入，具体表示为：

$$\square^t := \{\mathbf{g}_{mk}^t \mid \forall m, k\}. \quad (3-42)$$

考虑到训练过程与时间序列紧密相关，直接将 $\square^t$ 作为输入并不合理。用户移动行为引发的环境状态变化可视为时间序列演化过程，时空移动特征是预测下一时刻行为的关键依据。为此，本文引入时刻 $(t-1)$ 下的 $\mathbf{g}_{mk}$ 与 $R_{u,k}$ 作为辅助信息，与 $\square^t$ 共同参与

下一时刻动作预测。辅助信息定义为：

$$\square^{t-1} := \{\mathbf{g}_{mk}^{t-1}, R_{u,k}^{t-1} \mid \forall m, k\}. \quad (3-43)$$

神经网络最终输入为：

$$s^t := \{\square^{t-1}, \square^t\}. \quad (3-44)$$

此时，状态空间基数为 $2(MK) + K$ 。

2) 动作设计：演员网络根据当前状态 s 决策，输出 K 个 UE 的上行发射功率系数，可表示为：

$$a^t = [\eta_1^t, \dots, \eta_K^t]. \quad (3-45)$$

其中， η_k^t 满足约束 $0 \leq \eta_k^t \leq \eta_{\max}, \forall k$ 。

3) 奖励函数：本文以实际获得的用户速率作为环境反馈奖励，其定义为：

$$r^{t+1} = \sum_{k=1}^K R_{u,k}^t. \quad (3-46)$$

3.4.2 算法设计

所提算法的具体设计体现在以下四个方面。

3.4.2.1 Actor 网络分层设计

本文将 Actor 网络设计为分层结构，以实现功能模块的合理划分与信息的高效融合。具体而言，上层网络主要负责对辅助信息 $\square^{t-1}$ 进行特征提取与融合；随后，将上层网络输出与主信息 $\square^t$ 的特征结合，作为下层网络的输入。下层网络则基于上述融合特征完成最终动作的预测。

在将 $\square^t$ 输入下层网络前，本文采用自主设计的 DMAGNN 对 $\square^t$ 进行特征提取。DMAGNN 的运行流程包括以下几个方面：

- **节点特征初始化：**第 k 个用户设备在 t 时刻的节点特征初始化为：

$$x_k = \text{vec}(H_{\text{in},k}^H H_{\text{in},k}) \in \mathbb{R}^d, \quad (3-47)$$

其中, $H_{\text{in},k} \in \mathbb{C}^{M \times N}$ 表示第 k 个用户设备到 M 个接入点 (AP) 的信道矩阵。

- **动态图结构学习:** 在图结构构建过程中, 传统方法通常依赖固定地理距离 (如路径损耗) 定义节点间连接关系。然而在 CF-mMIMO 系统中, 用户分布密集且干扰特性复杂, 固定图结构难以反映瞬时信道状态的影响。为此, 本文借鉴图注意力网络 (GAT) 的思想, 引入可学习的参数化距离度量, 并采用双线性注意力机制计算节点 i 与节点 j 之间的关联强度:

$$a_{ij} = \sigma \left(\frac{(W_q x_i) \cdot (W_k x_j)^T}{\sqrt{b}} \right), \quad (3-48)$$

其中, b 为缩放因子, W_q 和 W_k 为可训练投影矩阵, 分别将节点特征 x_i 、 x_j 映射到查询空间和键空间。查询空间用于表征当前节点 (如用户 i) 的查询特征, 键空间用于表征其他节点 (如用户 j) 的被查询特征。通过二者内积衡量节点间的相关性与相似度, 使模型能够动态学习节点间的关联关系, 而非依赖静态图结构。

定理 2: 为降低全连接图 $O(K^2)$ 的计算复杂度, 本文设计了稀疏邻接矩阵:

$$A_{ij} = \begin{cases} 1, & \text{if } a_{ij} > \vartheta \text{ 且 } i \neq j \\ 0, & \text{otherwise,} \end{cases} \quad (3-49)$$

其中, 动态阈值 ϑ 通过自适应二分搜索确定, 以保证非零边数量满足 $|E| = O(K \log K)$ 。

邻接矩阵稀疏化后, 模型仅保留相关性较强的连接, 有助于提升泛化能力。

- **多尺度特征聚合:** 多尺度卷积通过聚合不同范围的邻域信息, 增强模型对复杂空间相关性的建模能力, 从而克服传统单层图卷积网络 (GCN) 感受野有限的不足。多跳信息聚合公式为:

$$\text{GCN}(A, H_{\text{in}}) = \sum_{l=0}^L \tilde{A}^l H_{\text{in}} W_l, \quad (3-50)$$

其中, $\tilde{A} = D^{-1/2} A D^{-1/2}$ 为邻接矩阵 A 的对称归一化形式, $D = \text{diag}(\sum_j A_{1j}, \dots, \sum_j A_{Kj})$ 为度矩阵, $W_l \in \mathbb{R}^{d \times d}$ 为第 l 跳的可训练权重矩阵。该设计具有如下特点:

- 局部性保持: $l = 0$ 时保留节点自身特征;
- 邻域扩展: $l = 1$ 时聚合一阶邻域信息, $l = 2$ 时捕获二阶邻域信息。

同时, 为不同跳数设置独立的 W_l , 以避免特征混淆。

- **门控特征更新机制:** 最后, 本文采用门控机制实现节点特征的选择性更新, 具体

Algorithm 1 DMAGNN-AC 功率分配算法

- 1: 输入: 回合次数 T_e , 探索次数 T , 折扣因子 γ , 学习率 α , 随机数据量 R_q , 批次大小 $\mathcal{N}$, 神经网络更新权重 τ 。
- 2: 初始化: 采用 He 初始化方法¹初始化 Critic 网络 $C(s, a; \omega_c)$ 、Actor 网络 $A(s; \omega_a)$ 的参数 ω_c 和 ω_a , 并且初始化 DMAGNN 的参数与初始状态 s^1 。
- 3: **for** $k = 1$ to T_e **do**
- 4: 设置环境变量初始值。
- 5: **for** $j = 1$ to T **do**
- 6: 二分搜索阈值 ϑ 。
- 7: **if** $j < R_q$ **then**
- 8: 以均匀概率随机生成动作 a^t 。
- 9: **else**
- 10: 由式 (3-47)–(3-49) 构建动态图。
- 11: 根据式 (3-50) 进行多尺度特征聚合。
- 12: 根据式 (3-51) 执行门控特征更新, 并输出新的特征向量 H_{out} 。
- 13: 根据式 (3-56) 选择动作 a^t 。
- 14: **end if**
- 15: 执行动作 a^t , 获得奖励 r^t 与下一状态 s^{t+1} 。
- 16: 存储该交互样本 (s^t, a^t, r^t, s^{t+1}) 。
- 17: 根据式 (3-60) 计算 Critic 网络梯度 $\nabla \omega_c$, 并沿负梯度方向更新 ω_c : $\omega_c \leftarrow \omega_c - \alpha \nabla \omega_c$ 。
- 18: 根据式 (3-59) 计算 Actor 网络梯度 $\nabla \omega_a$, 并沿正梯度方向更新 ω_a : $\omega_a \leftarrow \omega_a + \alpha \nabla \omega_a$ 。
- 19: 将目标评论家网络权重与目标行动者网络权重更新为:
- 20: $\omega'_c \leftarrow \tau \omega_c + (1 - \tau) \omega'_c$ 。
- 21: $\omega'_a \leftarrow \tau \omega_a + (1 - \tau) \omega'_a$ 。
- 22: **end for**
- 23: **end for**
- 24: 输出: 每个数据集可达到的最大用户速率 $R_{u,k}$ 。

过程如下:

$$Z = \text{GCN}(A, H_{\text{in}}), \quad (3-51)$$

$$G = \sigma(W_g[H_{\text{in}} \oplus Z]), \quad (3-52)$$

$$H_{\text{out}} = \text{LayerNorm}(G \odot H_{\text{in}} + (1 - G) \odot Z), \quad (3-53)$$

其中, Z 为卷积后生成的新特征, $W_g \in \mathbb{R}^{2d \times d}$ 为门控权重矩阵。门控机制可动态调整原始特征 H_{in} 与新特征 Z 的保留比例, 有效缓解梯度消失问题。

这种分层设计的优势在于, 上层网络能够充分挖掘前一时刻信息中的关键特征, 为下层网络提供更具价值的先验信息。因此, 下层网络在预测动作时, 可以更精确地基于

¹He 初始化是深度学习中一种神经网络权重初始化方法, 该方法基于 ReLU 激活函数的特性, 用于提升训练过程中的收敛速度与网络性能。

时刻 t 的信息进行决策。该设计提升了整体网络的学习效果与决策精度。

3.4.2.2 网络更新频率的优化策略

为进一步提升网络的学习效率，本文提出了一种目标网络更新频率（UF）的动态自适应调整策略。在每轮完整训练开始时，首先将目标网络更新频率初始化为 300，并将初始最大奖励（MR）设为 0。随着训练过程的推进，持续累积并计算奖励值。当训练步数达到当前设定的更新频率时，计算当前阶段的平均奖励（AR），并与历史最大奖励（MR）进行比较。若平均奖励超过最大奖励，则将最大奖励更新为当前平均奖励，并依据两者差值 D_{value} 动态调整网络更新频率，具体调整公式如下：

$$\text{UF} = \text{UF} \times \log_2 \left(1 + \frac{1}{1 + e^{D_{\text{value}}}} \right). \quad (3-54)$$

该公式反映：当 D_{value} 变化幅度较大时，表明网络学习效果显著提升，此时应加快目标网络的更新频率，以便更及时地跟踪最优策略；反之，若 D_{value} 变化较小，则适当降低更新频率，防止因频繁更新导致网络不稳定或陷入局部最优。

3.4.2.3 训练回滚策略

此外，当平均奖励（AR）低于最大奖励（MR）时，将网络状态回滚至本轮训练开始时的状态并重新训练。该策略有助于网络跳出可能存在的局部最优解，重新探索更优的策略空间，从而提升整体学习的成功率与效率。

3.4.2.4 训练过程

如图 3-2 所示，DMAGNN-AC 框架主要由行动者网络（Actor）与评论家网络（Critic）两部分组成。智能体通过行动者网络 $A(s; \omega_a)$ ，依据当前状态 s 生成确定性动作 a ，其中 ω_a 为行动者网络参数。评论家网络 $C(s_c, a; \omega_c)$ 则对当前状态 s_c 下所选动作 a 进行价值评估。确定性策略可表示为：

$$a^* = A(s; \omega_a). \quad (3-55)$$

为提升模型泛化能力，本文在动作选择中引入高斯噪声，具体表达式如下：

$$a := [A(s; \omega_a) + \mathbf{n}]_0^{P_{\max}}, \quad (3-56)$$




图 3-3 Network architecture of MADQIN.

其中 $\mathbf{n} \sim \mathcal{CN}(0, 1)$, 动作 a 的取值区间为 $[0, P_{\max}]$ 。

为获得最优策略, 行动者网络与评论家网络协同优化, 行动者网络参数通过最大化评论家网络输出进行更新:

$$\omega_a^* = \underset{\omega_a}{\operatorname{argmax}} C(s_c, a; \omega_a). \quad (3-57)$$

评论家网络则通过最小化预测值与实际奖励的误差来优化参数, 具体为:

$$\omega_c^* = \underset{\omega_c}{\operatorname{argmin}} \frac{1}{2} (C(s_c, a; \omega_c)|_{a=A(s; \omega_a)} - r_s^a)^2. \quad (3-58)$$

行动者网络参数的更新采用梯度上升法, 表达式为:

$$\operatorname{abla}_{\omega_a} J(\omega_a) \approx \frac{1}{T} \sum_{t=1}^T \nabla_a C(s^t, a^t; \omega_c) \nabla_{\omega_a} A(s^t; \omega_a). \quad (3-59)$$

评论家网络参数的更新则通过最小化以下损失函数实现:

$$\nabla_{\omega_c} L(\omega_c) \approx \frac{1}{T} \sum_{t=1}^T (y^t - C(s^t, a^t; \omega_c))^2, \quad (3-60)$$

其中 $y^t = r^t + \gamma C(s^{t+1}, a^{t+1}; \omega'_c)$, γ 为折扣因子。该算法的详细实现过程见前述算法 1。

Algorithm 2 MADQIN Algorithm

```

1: Input: Episode times  $N_e$ , exploration times  $T$ , target network update frequency  $T_u$ , discount
   factor  $\gamma$ , learning rate  $\alpha$ , and random data quantity  $R_q$ .
2: Initialization: Initialize MADQIN  $Q(s, a; \omega_q)$  parameter  $\omega_q$  with He initialization method.
3: for  $k = 1$  to  $N_e$  do
4:     Creating environment object  $\mathcal{O}_e$  and neural network object  $\mathcal{O}_d$ .
5:     Initialize status  $s^1$ .
6:     for  $j = 1$  to  $T$  do
7:         if  $j < R_q$  then
8:             Randomly select action set  $a^t \in \mathcal{A}$  with uniform probability.
9:         else
10:            Select action  $a^t$  by (3-63).
11:        end if
12:        Execute action  $a^t$ , obtain reward  $r^t$ , and next state  $s^{t+1}$ .
13:        Store the transaction  $(s^t, a^t, r^t, s^{t+1})$ .
14:        Minimizing the loss to update the MADQIN network.
15:
16:    end for
17: end for
18: Output: Learned DQN  $Q(s, a; \omega_q)$ .
    
```

$$L^t(\omega_q) = (r_{s,a}^t + \gamma \max_{a^{t+1}} Q(s^{t+1}, a^{t+1}; \omega_{target}) - Q(s^t, a^t; \omega_q))^2.$$

3.5 MADQIN 算法设计

鉴于 ADC 分辨率具有离散特性, 本文采用离散动作空间的深度 Q 网络 (DQN) 作为优化基础, 设计了多智能体深度 Q 集成网络 (MADQIN) 以实现 ADC 分辨率的自适应分配。如图 3-3 所示, MADQIN 主要由主 Q 网络 (Q-Network) 和目标 Q 网络 (Q-target) 两部分组成。主 Q 网络用于预测系统中各智能体动作的最大 Q 值, 并将其作为预测奖励 r_p , 智能体据此选择 Q 值最大的动作以获得实际奖励 r 。目标 Q 网络则用于预测下一状态下的 Q 值 r_t , 并将 r 与 r_t 之和作为真实奖励 r' 。通过不断迭代, 最小化 r_p 与 r' 之间的误差, 实现 Q 网络参数 ω_q 的优化。其优化目标可表述为:

$$\omega_q^* = \underset{\omega_q}{\operatorname{argmin}} \frac{1}{2} (Q(s, a; \omega_q) - r_s^a)^2. \quad (3-61)$$

ω_q 的梯度计算方式为:

$$\nabla \omega_q = (Q(s, a; \omega_q) - r_s^a) \nabla_{\omega_q} Q(s, a; \omega_q). \quad (3-62)$$

表 3-1 System basic parameter settings.

Parameters	Values
Carrier frequency	1.9 GHz
Bandwidth	20 MHz
Noise figure	9 dB
AP antenna height	15 m
User antenna height	1.65 m
Coherence interval length τ	200
Pilot length τ_p	20
Pilot transmission power ρ_p	200 mW
ADC resolution b_m	10
M, K, N	100, 20, 4
δ_{sh}, L, d_1, d_0	8 dB, 140.7 dB, 50 m, 10 m

在 DRL 环境下, MADQIN 输出层维度设为 $[M, AD]$, 其中 AD 表示每个接入点 (AP) 可选的 ADC 分辨率数量。网络输出即为 M 个 AP 在给定状态下各自可能可选动作的 Q 值。为获得最优动作策略, 需求解使 Q 值最大的动作 a^* , 即:

$$a^* = \underset{a}{\operatorname{argmax}} Q(s, a; \omega_q). \quad (3-63)$$

MADQIN 的输入输出设计与 DMAGNN-AC 保持一致。不同于传统贪心策略最大化样本多样性的方法, 本文在初始阶段采用随机动作策略, 并将产生的数据纳入经验回放缓冲区, 以提升模型的鲁棒性和适应性。实验结果表明, 该策略在特定场景下具有更优表现。此外, 为进一步提升算法性能, 动作执行时引入高斯随机噪声, 其表达式为:

$$a := [a^* + \mathbf{n}]_{b_m^{\min}}^{b_m^{\max}}. \quad (3-64)$$

MADQIN 的详细执行流程总结于本页顶部的算法 2 中。

3.6 数值结果与分析

本节通过大量仿真实验, 对配置非线性 PA 与低分辨率 ADC 的 CF-mMIMO 系统性能进行系统性分析。如无特殊说明, 实验参数均采用表 I 所示的标准配置。

本文采用文献^[45]中非线性 PA 模型的参数设置, 其中 $a_1 = 13.85$, $a_3 = -4.074$ 。大

表 3-2 Neural Network Parameter Settings.

	Parameters	Values
DMAGNN-AC	Discount factor γ	0.1
	Learning rate α	0.001
	Size of experience replay buffer $\mathcal{B}$	10000
	Frequency of updating initial trial status $\mathcal{H}$	500
	Update neural network parameter weights τ	0.005
	Warm up times $\mathcal{W}$	256
MADQIN	Learning rate α	0.001
	Discount factor γ	0.1
	Size of experience replay buffer $\mathcal{B}$	1000
	Batch size ς	200
	Warm up times $\mathcal{W}$	200

尺度衰落系数 β_{mk} 采用如下建模方式，以更准确反映实际通信环境中的信号衰减特性：

$$\beta_{mk} = \text{PL}_{mk} \cdot 10^{\frac{\delta_{\text{sh}}^{z_{mk}}}{10}}, \quad (3-65)$$

其中 $10^{\frac{\delta_{\text{sh}}^{z_{mk}}}{10}}$ 用于模拟阴影衰落， $z_{mk} \sim \mathcal{CN}(0, 1)$ 。路径损耗 PL_{mk} 采用文献^[4]提出的三斜率模型，具体为：

$$\text{PL}_{mk} = \begin{cases} -L - 35 \log_{10}(d_{mk}), & d_{mk} > d_1 \\ -L - 15 \log_{10}(d_1) - 20 \log_{10}(d_{mk}), & d_0 < d_{mk} \leq d_1 \\ -L - 15 \log_{10}(d_1) - 20 \log_{10}(d_0), & d_{mk} \leq d_0 \end{cases} \quad (3-66)$$

其中 d_{mk} 表示第 m 个 AP 与第 k 个 UE 之间的距离。需注意，当 $d_{mk} < d_1$ 时不考虑阴影效应。

为验证所提算法性能，本文将其与传统全功率发射方案进行对比。实验结果表明，在各类环境下，所提算法均能在约 2000 步内收敛至理想性能。两种算法的主要参数配置见表 II。




图 3-4 不同 AP 数量下的上行可达和速率, $K = 20$, $N = 20$ 。

首先, 图3-4 展示了上行可达和速率随接入点 (AP) 数量变化的关系。本文还对式(3-34)的“解析结果”与式(3-33)的“仿真结果”进行了对比分析。仿真结果基于蒙特卡洛方法, 在 10^4 次独立同分布 (i.i.d.) 信道实现下获得。结果显示, 仿真与解析结果高度一致, 充分验证了理论推导的准确性, 为后续相关研究奠定了基础。




图 3-5 全功率传输下, 不同 AP 和 UE 数量时单用户速率的累积分布函数 (CDF), $N = 4$, $b_m = 10$ 。

图3-5 展示了全功率传输场景下, 不同 AP 和 UE 数量对应的单用户速率累积分布函数 (CDF)。可以观察到, 当 $M = 15$ 时, 随着 UE 数量增加, 平均单用户速率呈下降趋势。这是由于 UE 密度升高导致导频污染和多用户干扰加剧。值得注意的是, 尽管平均速率下降, 用户速率下界却有所提升。其原因在于, 当 AP 数量远大于 UE 数量时,

系统尚未达到最大服务容量；而当 UE 数量超过 AP 数量时，用户速率受干扰影响显著，此时可通过增加 AP 数量加以缓解。随着 AP 和 UE 数量的增加，CDF 曲线逐步右移并最终收敛于 1.5 bits/s/Hz 的共同上限。结果表明，在本研究场景下，单纯增加 AP 和 UE 数量无法无限提升用户速率，但可有效提升速率下界，增强系统数据传输的稳定性，体现了 CF-mMIMO 系统为所有用户提供均匀服务质量的优点。




图 3-6 在多种影响因素存在时，低分辨率 ADC 的比特位数对上行用户和速率的影响。




图 3-7 在多种影响因素存在时，低分辨率 ADC 的比特位数对上行用户和速率的影响。

图 3-6 和图 3-7 分别展示了在多种影响因素下，低分辨率 ADC 比特数对上行用户速率的影响。每组实验均假设所有 AP 配备相同分辨率的 ADC。从结果可以看出，在达到峰值速率前，提升 ADC 分辨率能够显著提高用户速率；但在更大规模下，AP 数量成为决定用户速率的主导因素，说明增加 AP 数量可有效补偿低分辨率 ADC 带来的速率损失。此外，天线数量不足会限制系统的最大速率性能。如图 3-6 所示，仅当 $N \geq 50$

时，用户速率才接近极限，表明实际部署中需根据 AP 数量合理配置天线数以充分发挥系统性能。随着天线数增加，单用户速率逐渐趋于上限 1.5 bits/s/Hz，这与前述结论一致。当 N 相对于 $\rho_u \sum_{m=1}^M \alpha_m (1 - \alpha_m) \left(\sum_{k=1}^K \beta_{mk} \Omega_k + 1 \right) \gamma_{mk}$ 足够大时，其对用户速率的影响趋于减弱。此外，图 3-6 与图 3-7 的峰值速率基本一致，说明单纯提升 ADC 分辨率或 AP 天线数均无法突破系统固有的速率上限。




图 3-8 Comparing the uplink sum-rate in a CF-mMIMO system with nonlinear PAs and low-resolution ADCs versus the ideal hardware scenario, with $b_m = 10$.

图 3-8 对比了理想与非理想硬件条件下，CF-mMIMO 系统在不同 AP 数量和天线数量下的可达用户速率。结果显示，在理想硬件条件下，随着 AP 和天线数量增加，用户速率最高可超过 90 bits/s/Hz；而在非线性 PA 和低分辨率 ADC 影响下，峰值速率被限制在 30 bits/s/Hz 左右。可见，硬件损伤导致系统速率下降近 70%，凸显了针对硬件损伤系统开展深入研究的必要性。




图 3-9 Rate comparison based on different hardware impairments, with $b_m = 10$, $K = 20$.

随后，为深入分析导致用户速率显著下降的主要因素，图 3-9 通过控制硬件损伤变量设计了对比实验。结果表明，在 ADC 分辨率趋于理想的情况下，PA 的非线性成为限制用户速率上限的关键瓶颈，这进一步验证了式 (3-34) 的理论分析。




图 3-10 对比了 DMAGNN-AC 算法与全功率传输策略、DDPG 算法的优化性能， $b_m = 10$, $N = 4$ 。




图 3-11 在总比特数保持恒定的前提下，本文所提的 MADQIN 算法相比平均分配策略在性能上有显著提升， $b_{\text{total}} = 135$, $M = 15$, $K = 5$ 。

接下来，本文利用所提算法对整个系统中各 AP 与 UE 的实验参数进行精细调控，从不同角度验证算法带来的性能提升。图 3-10 对比了 DMAGNN-AC 算法与全功率传输策略、DDPG 算法的优化性能。DDPG 算法通过与环境交互探索逐步逼近最优解，在达到全功率策略性能上限后，可将单用户速率进一步提升 2.8 bit/s/Hz。此外，在引入 DMAGNN 作为特征提取模块后，速率的累积分布曲线相对 DDPG 进一步右移，验证了 DMAGNN 通过干扰建模与多尺度特征融合，能够提升算法收敛性能并改善最小用户速率。不同 AP-UE 配置下的对比结果表明，系统最高用户速率稳定在 3.8 bit/s/Hz 左右，即为用户速率的最终性能边界。

如图 3-11 所示，在总比特数保持恒定的前提下，本文所提的 MADQIN 算法相比平均分配策略在性能上有显著提升。随着天线数量增加，用户速率呈逐步上升趋势。值得注意的是，调整 AP 的 ADC 分辨率仅能带来较小的性能增益。这一现象可由式 (3-34) 解释：速率主要由 ADC 总分辨率决定，无论信号是期望信号还是用户间干扰，仅有 ADC 量化噪声项与分辨率的具体分配有关。因此，该影响处于可接受范围内。

图 3-12 和图 3-13 分别给出了两种算法在迭代过程中的损失函数值。为使结果更具普适性，本文对三组损失结果进行了对比。可以看出，两种算法在迭代 1200 轮后均呈现出明显的收敛趋势，充分证明了两种算法均具备优异的性能稳定性。




图 3-12 DMAGNN-AC 算法的收敛性。




图 3-13 MADQIN 算法的收敛性。

3.7 本章小结

本章系统研究了在存在非线性 PA 与低分辨率 ADC 条件下，CF-mMIMO 系统的上行数据传输性能，推导了可达用户速率的闭式表达式，并深入分析了硬件损伤对系统性能的影响。研究表明，非理想硬件会显著限制系统的速率上限。针对上述问题，本文提出了基于深度强化学习的 DMAGNN-AC 功率控制算法，有效抑制了多用户干扰，并显著提升了系统整体性能及最小用户速率下界。进一步地，结合 MADQIN 算法实现了 ADC 分辨率的自适应优化，进一步提升了系统的速率表现。仿真结果验证了所提算法在低质量硬件条件下的有效性与实用性，为实际 CF-mMIMO 系统的工程实现提供了理论支撑。

第四章 非理想硬件条件下去蜂窝大规模 MIMO 系统的 URLLC 服务资源分配策略

去蜂窝大规模多输入多输出系统 (CF-mMIMO) 具有大量天线和空间稀疏部署的特点, 有望为海量设备提供超可靠和低延迟通信 (URLLC) 服务。然而, 这种方法的实施需要大量的部署成本, 并且不可避免地需要使用非理想的硬件。本文针对非理想硬件条件下 CF-mMIMO 系统的 URLLC 性能优化问题, 构建了用户端非线性功率放大器与接入点低分辨率模数转换器 (ADC) 的混合损伤模型, 推导了上行链路用户速率闭合表达式。为降低传统优化算法的计算复杂度, 提出基于图神经网络 (GNN) 与深度强化学习 (DRL) 融合的智能功率控制策略, 通过图嵌入技术建模用户空间相关性, 动态抑制硬件损伤与时变信道干扰。所提方案在保持毫秒级时延的同时, 为工业自动化等物联网应用提供理论与技术支撑。

4.1 引言

随着移动通信技术的不断演进, 第五代及未来移动通信网络正推动智能制造、智能交通等物联网应用的快速发展。该网络主要承载超可靠低延迟通信 (URLLC)、增强型移动宽带 (eMBB) 和大规模机器类通信 (mMTC) 三大核心场景, 各场景对可靠性、时延、传输速率及连接密度的服务质量提出了差异化且严苛的要求。其中, URLLC 以极端事件响应为目标, 要求时延控制在 1-10 毫秒、误块率低至 10^{-5} - 10^{-7} , 成为支撑机器人协同控制、自动驾驶等关键任务的核心技术。然而, URLLC 的短传输块特性使得传统香农容量理论难以直接适用, 现有蜂窝网络架构在保障服务质量方面也面临结构性瓶颈。

去蜂窝大规模多输入多输出 (CF-mMIMO) 系统作为新一代网络架构, 为 URLLC 服务提供了创新性解决方案。该系统通过分布式部署大量接入点 (AP), 并与中央处理单元 (CPU) 协同工作, 有效消除蜂窝边缘干扰, 实现全域均匀服务覆盖。与传统集中式大规模 MIMO 相比, CF-mMIMO 缩短了 AP 与 UE 的空间距离, 显著降低信号传播衰落; 其稀疏空间布局与多元宏观特征能够稳定信道状态, 形成独特的信道硬化效应。这些技术特性为 URLLC 可靠性提升提供了坚实保障, 展现出显著的技术优势。

本章以 CF-mMIMO 系统的 URLLC 服务为研究对象, 针对实际硬件损伤问题, 深入

分析功率分配策略对系统性能的影响。为实现系统能耗优化与硬件损伤量化分析,采用无记忆多项式模型刻画用户设备非线性功率放大器特性,并结合接入点低分辨率 ADC 量化技术,推导上行链路用户速率解析表达式,为后续研究奠定理论基础。

4.2 可实现 URLLC 速率

传统的香农容量是在假设码字长度趋于无穷大、解码错误概率趋近于零的理想条件下推导的。然而,在 URLLC 场景下,由于对时延和可靠性的极高要求,实际通信往往采用有限块长编码,此时香农容量理论已不再适用。为准确刻画有限块长下的系统性能,URLLC 通常采用有限块长编码理论对可实现速率进行分析。

基于第三章推导的非理想硬件条件下 CF-mMIMO 系统上行可达速率 $R_{u,k}$,本节进一步考虑有限块长编码约束,推导 URLLC 场景下的可实现速率。根据有限块长信息论,第 k 个用户的 URLLC 可实现速率可表示为:

$$r_{u,k} = \log_2(1 + R_{u,k}) - \chi \left(1 - \frac{1}{(1 + R_{u,k})^2} \right)^{1/2} \quad (4-1)$$

其中, $R_{u,k}$ 为第三章式 (3-23) 给出的非理想硬件条件下用户可达速率, $\chi = Q^{-1}(\varepsilon) \log_2 e$, $Q^{-1}(\cdot)$ 为高斯 Q 函数的反函数, ε 为目标误块率。高斯 Q 函数定义为 $Q(x) = \frac{1}{\sqrt{2\pi}} \int_x^\infty \exp(-t^2/2) dt$ 。

上述表达式综合考虑了有限块长下的误码概率约束与非理想硬件损伤影响,更加贴合 URLLC 实际应用场景,为后续资源分配与系统优化提供理论基础。

4.3 算法设计

在 CF-mMIMO 系统中,由于 UE 与 AP 的分布式部署及信道动态变化,传统集中式优化方法难以实时捕捉网络拓扑的时空关联性。为此,本文提出一种基于图神经网络的动态干扰管理算法。该算法通过图神经网络基于信道特征动态提取用户之间的干扰来辅助 DRL 算法预测,实现多用户干扰关系的自适应建模与功率控制的联合优化。

4.3.1 用户节点特征建模

为了精确建模用户之间的空间分布以及干扰特性,将每个 UE 定义为图中的节点。考虑到信道状态信息包含幅度和相位两种物理意义明确的特征,本文分别对幅度和相位进行独立建模与融合处理,以充分挖掘信道信息的表征能力。

首先, 定义用户 k 到所有 AP 的聚合信道向量。根据第三章系统模型, 第 m 个 AP 与第 k 个 UE 之间的信道向量为 $\mathbf{g}_{mk} \in \mathbb{C}^{N \times 1}$, 其中 N 为每个 AP 的天线数。将用户 k 到所有 M 个 AP 的信道向量进行聚合, 得到聚合信道向量:

$$\mathbf{g}_k = [\mathbf{g}_{1k}^T, \mathbf{g}_{2k}^T, \dots, \mathbf{g}_{Mk}^T]^T \in \mathbb{C}^{MN \times 1} \quad (4-2)$$

对聚合信道向量 $\mathbf{g}_k$ 进行幅度-相位分解:

$$\mathbf{g}_k = \mathbf{A}_k \odot \exp(j\Phi_k) \quad (4-3)$$

其中, $\mathbf{A}_k = |\mathbf{g}_k|$ 表示信道幅度向量, $\Phi_k = \angle \mathbf{g}_k$ 表示信道相位向量, $\odot$ 表示逐元素乘法。

基于此分解, 节点特征采用双分支结构进行编码。幅度分支特征 $\mathbf{f}_k^{\text{amp}}$ 捕获信号强度与硬件损伤信息:

$$\mathbf{f}_k^{\text{amp}} = [\mathbf{A}_k^{(1)}, \mathbf{A}_k^{(2)}, \dots, \mathbf{A}_k^{(M)}, \eta_k, |a_{3k}|, \text{SINR}_k^{\text{est}}]^T \quad (4-4)$$

其中, $\mathbf{A}_k^{(m)} = |\mathbf{g}_{mk}|$ 表示用户 k 到第 m 个 AP 的信道幅度向量, η_k 表示当前发射功率, $|a_{3k}|$ 量化了功率放大器非线性失真程度, $\text{SINR}_k^{\text{est}}$ 为估计的信干噪比。

相位分支特征 $\mathbf{f}_k^{\text{ph}}$ 编码信道方向性与空间相关性:

$$\mathbf{f}_k^{\text{ph}} = [\Phi_k^{(1)}, \Phi_k^{(2)}, \dots, \Phi_k^{(M)}, \cos(\theta_k), \sin(\theta_k), \Delta\varphi_k]^T \quad (4-5)$$

其中, $\Phi_k^{(m)} = \angle \mathbf{g}_{mk}$ 表示用户 k 到第 m 个 AP 的信道相位向量, θ_k 为用户 k 的空间方位角, $\Delta\varphi_k$ 表示相位抖动方差, 反映信道时变特性。

最终, 节点特征通过特征融合层进行整合。首先, 幅度分支和相位分支分别经多层感知机映射到统一维度的特征空间:

$$\mathbf{h}_k^{\text{amp}} = \mathbf{W}_{\text{amp}}^{(2)} \sigma(\mathbf{W}_{\text{amp}}^{(1)} \mathbf{f}_k^{\text{amp}} + \mathbf{b}_{\text{amp}}^{(1)}) + \mathbf{b}_{\text{amp}}^{(2)} \quad (4-6)$$

$$\mathbf{h}_k^{\text{ph}} = \mathbf{W}_{\text{ph}}^{(2)} \sigma(\mathbf{W}_{\text{ph}}^{(1)} \mathbf{f}_k^{\text{ph}} + \mathbf{b}_{\text{ph}}^{(1)}) + \mathbf{b}_{\text{ph}}^{(2)} \quad (4-7)$$

其中, $\mathbf{W}_{\text{amp}}^{(1)}$, $\mathbf{W}_{\text{amp}}^{(2)}$ 和 $\mathbf{W}_{\text{ph}}^{(1)}$, $\mathbf{W}_{\text{ph}}^{(2)}$ 分别为两个分支 MLP 的权重矩阵, $\mathbf{b}$ 为偏置向量, $\sigma(\cdot)$ 为 ReLU 激活函数。

然后，通过拼接与投影操作实现双分支信息融合：

$$\mathbf{f}_k = \mathbf{W}_{\text{fuse}} \left[\mathbf{h}_k^{\text{amp}} \parallel \mathbf{h}_k^{\text{ph}} \right] + \mathbf{b}_{\text{fuse}} \quad (4-8)$$

其中， $\parallel$ 表示向量拼接操作， $\mathbf{W}_{\text{fuse}} \in \mathbb{R}^{D \times 2D}$ 为融合投影矩阵， D 为节点特征的最终维度。

4.3.2 干扰边特征建模

为准确刻画用户间的干扰耦合关系，在图结构中引入边特征建模。对于任意用户节点对 (i, k) ，其边特征 $\mathbf{e}_{ik}$ 定义为：

$$\mathbf{e}_{ik} = [d_{ik}, I_{ik}]^T \quad (4-9)$$

其中， d_{ik} 表示用户 i 与用户 k 之间的归一化距离，定义为 $d_{ik} = \|\mathbf{x}_i - \mathbf{x}_k\|/d_{\max}$ ， $\mathbf{x}_i$ 和 $\mathbf{x}_k$ 分别为用户 i 和用户 k 的位置坐标， $d_{\max}$ 为系统覆盖区域的最大距离。该特征用于表征用户间的空间邻近程度，距离越近则潜在干扰越强。

I_{ik} 表示用户间的干扰强度，定义为：

$$I_{ik} = \frac{\|\mathbf{g}_i^H \mathbf{g}_k\|_F^2}{MN} \quad (4-10)$$

其中， $\|\cdot\|_F$ 表示 Frobenius 范数。该指标量化了用户间的信道相关性，取值越大表示干扰越强。

边的存在性由干扰阈值判定：

$$\mathcal{E}_{ik} = \begin{cases} 1, & \text{if } I_{ik} > \epsilon_{\text{th}} \\ 0, & \text{otherwise} \end{cases} \quad (4-11)$$

其中 ϵ_{th} 为干扰强度阈值，典型设置为 $\epsilon_{\text{th}} = 0.1$ 。该稀疏化策略有效降低图结构复杂度，聚焦于关键干扰链路。

4.3.3 图神经网络消息传递机制

基于构建的节点特征和边特征，采用图注意力网络（GAT）实现消息传递与特征聚合。GAT 的核心思想是通过注意力机制自适应地学习邻居节点的重要性权重，从而实现差异化信息聚合。

在第 l 层消息传递中，节点 k 首先通过线性变换将其特征映射到新的特征空间：

$$\mathbf{h}_k^{(l)} = \mathbf{W}^{(l)} \mathbf{h}_k^{(l-1)} \quad (4-12)$$

其中， $\mathbf{h}_k^{(l)}$ 为节点 k 在第 l 层的隐藏状态（ $\mathbf{h}_k^{(0)} = \mathbf{f}_k$ ）， $\mathbf{W}^{(l)} \in \mathbb{R}^{D \times D}$ 为可学习的权重矩阵。

然后，计算节点 k 与邻居节点 i 之间的注意力系数。为充分利用边特征信息，采用边增强的注意力机制：

$$e_{ik}^{(l)} = \text{LeakyReLU} \left(\mathbf{a}^{(l)T} \left[\mathbf{h}_i^{(l)} \parallel \mathbf{h}_k^{(l)} \parallel \mathbf{W}_e^{(l)} \mathbf{e}_{ik} \right] \right) \quad (4-13)$$

其中， $\parallel$ 表示向量拼接操作， $\mathbf{a}^{(l)}$ 为注意力向量， $\mathbf{W}_e^{(l)}$ 为边特征变换矩阵。该设计将节点特征与边特征联合建模，使注意力系数能够感知用户间的干扰强度。

注意力系数通过 softmax 函数归一化：

$$\alpha_{ik}^{(l)} = \frac{\exp(e_{ik}^{(l)})}{\sum_{j \in \mathcal{N}(k) \cup \{k\}} \exp(e_{jk}^{(l)})} \quad (4-14)$$

其中， $\mathcal{N}(k)$ 为节点 k 的邻居节点集合，自环的引入使节点能够保留自身特征信息。

为增强模型的表达能力，采用多头注意力机制。设 H 为注意力头数，各头独立计算注意力系数并进行特征聚合：

$$\mathbf{h}_k^{(l+1)} = \sigma \left(\frac{1}{H} \sum_{h=1}^H \sum_{i \in \mathcal{N}(k) \cup \{k\}} \alpha_{ik}^{(l,h)} \mathbf{W}^{(l,h)} \mathbf{h}_i^{(l)} \right) \quad (4-15)$$

其中， $\alpha_{ik}^{(l,h)}$ 和 $\mathbf{W}^{(l,h)}$ 分别为第 h 个注意力头的注意力系数和权重矩阵， $\sigma(\cdot)$ 为 ReLU 激活函数。多头机制使模型能够从不同子空间捕获节点间的关联特征。

经过 L 层消息传递后，得到各节点的图嵌入表示 $\mathbf{z}_k = \mathbf{h}_k^{(L)}$ ，该嵌入融合了局部拓扑结构、信道状态及干扰关系信息，为后续功率控制决策提供高维表征。

4.3.4 基于 Actor-Critic 的功率控制决策

基于 GNN 提取的图嵌入表示，将功率控制问题建模为马尔可夫决策过程（MDP），采用近端策略优化（PPO）算法进行求解。MDP 由状态空间 $\mathcal{S}$ 、动作空间 $\mathcal{A}$ 、状态转移概率 $\mathcal{P}$ 和奖励函数 $\mathcal{R}$ 四元组定义。

系统状态由各用户的图嵌入向量与全局上下文特征组成。对于时隙 t ，状态定义为：

$$\mathbf{s}_t = [\mathbf{z}_1^{(t)}, \mathbf{z}_2^{(t)}, \dots, \mathbf{z}_K^{(t)}, \mathbf{c}^{(t)}] \quad (4-16)$$

其中， $\mathbf{z}_k^{(t)} \in \mathbb{R}^D$ 为用户 k 在时隙 t 经 GNN 提取的图嵌入，融合了信道状态、干扰关系及拓扑结构信息； $\mathbf{c}^{(t)} = [\bar{r}^{(t)}, \bar{\eta}^{(t)}, \bar{I}^{(t)}]$ 为全局上下文特征，分别表示系统平均速率、平均发射功率和平均干扰强度。

动作空间定义为各用户发射功率的调整系数：

$$\mathbf{a}_t = [\delta_1^{(t)}, \delta_2^{(t)}, \dots, \delta_K^{(t)}], \quad \delta_k^{(t)} \in [0, 1] \quad (4-17)$$

实际发射功率为 $\eta_k^{(t)} = \delta_k^{(t)} \cdot \eta_{\max}$ ，其中 $\eta_{\max}$ 为最大发射功率约束。

Actor 网络负责输出功率控制策略。对于用户 k ，其策略均值由图嵌入经全连接层变换得到：

$$\mu_k^{(t)} = \mathbf{W}_\mu^{(2)} \sigma \left(\mathbf{W}_\mu^{(1)} \mathbf{z}_k^{(t)} + \mathbf{b}_\mu^{(1)} \right) + \mathbf{b}_\mu^{(2)} \quad (4-18)$$

其中， $\mathbf{W}_\mu^{(1)} \in \mathbb{R}^{D_\mu \times D}$ 和 $\mathbf{W}_\mu^{(2)} \in \mathbb{R}^{1 \times D_\mu}$ 为可学习权重矩阵， D_μ 为隐藏层维度。策略分布采用高斯分布建模：

$$\pi_\theta(\mathbf{a}_t | \mathbf{s}_t) = \prod_{k=1}^K \mathcal{N} \left(\delta_k; \mu_k^{(t)}, \sigma^2 \right) \quad (4-19)$$

其中，标准差 σ 为可学习参数，控制探索程度。

Critic 网络评估当前状态的期望累积奖励。首先对所有用户的图嵌入进行全局平均池化：

$$\bar{\mathbf{z}}^{(t)} = \frac{1}{K} \sum_{k=1}^K \mathbf{z}_k^{(t)} \quad (4-20)$$

然后，将池化后的嵌入与全局上下文特征拼接，经多层感知机输出状态值：

$$V_\phi(\mathbf{s}_t) = \mathbf{W}_v^{(2)} \sigma \left(\mathbf{W}_v^{(1)} [\bar{\mathbf{z}}^{(t)} \parallel \mathbf{c}^{(t)}] + \mathbf{b}_v^{(1)} \right) + \mathbf{b}_v^{(2)} \quad (4-21)$$

其中, $\mathbf{W}_v^{(1)} \in \mathbb{R}^{D_v \times (D+3)}$ 和 $\mathbf{W}_v^{(2)} \in \mathbb{R}^{1 \times D_v}$ 为可学习权重矩阵。该设计通过聚合全局信息, 评估当前功率配置的系统级价值。

4.3.5 奖励函数设计

针对 CF-mMIMO 系统中 URLLC 功率控制问题, 奖励函数综合考虑系统频谱效率及 URLLC 服务质量约束。本文设计的奖励函数由系统和速率及 URLLC 约束惩罚构成, 各分量分别对应不同的优化目标。

系统和速率作为无线通信系统的核心性能指标, 直接表征系统容量与频谱利用效率。对于时隙 t , 系统和速率项定义为:

$$\mathcal{R}_t^{\text{sum}} = \sum_{k=1}^K r_{u,k}^{(t)} \quad (4-22)$$

其中, $r_{u,k}^{(t)}$ 为用户 k 在时隙 t 的 URLLC 可实现速率。该奖励项引导智能体探索能够最大化系统和容量的功率分配策略。

URLLC 场景对可靠性与时延具有严格要求, 违反约束将导致工业控制、远程医疗等关键应用的严重故障。本文采用惩罚函数机制确保服务质量约束:

$$\mathcal{R}_t^{\text{urllc}} = -\lambda_\varepsilon \sum_{k=1}^K \mathbf{1}_{\{\varepsilon_k^{(t)} > \varepsilon_{\text{th}}\}} - \lambda_\tau \sum_{k=1}^K \mathbf{1}_{\{D_k^{(t)} > D_{\text{th}}\}} \quad (4-23)$$

其中, $\varepsilon_k^{(t)}$ 和 $D_k^{(t)}$ 分别表示用户 k 在时隙 t 的解码错误概率与端到端时延; ε_{th} 和 D_{th} 为 URLLC 约束阈值, 依据 3GPP TS 38.913 标准, 典型值分别设定为 $\varepsilon_{\text{th}} = 10^{-5}$ 和 $D_{\text{th}} = 1$ ms; λ_ε 和 λ_τ 为惩罚系数, 用于调节违反约束的代价强度。

解码错误概率 $\varepsilon_k^{(t)}$ 由有限块长信息论给出, 其表达式为 $\varepsilon_k \approx Q\left(\frac{nC_k - L_k}{\sqrt{nV_k}}\right)$, 其中 C_k 为香农容量, V_k 为信道色散, n 为块长, L_k 为传输比特数。该概率与信道状态、发射功率及传输块长紧密耦合, 当信道条件恶化或功率配置不足时, 错误概率升高并触发惩罚机制, 引导智能体调整功率策略以满足可靠性要求。端到端时延 $D_k^{(t)}$ 由传输时延、处理时延与排队时延构成, 在 URLLC 场景下需严格约束于阈值范围内。

综合上述设计, 总奖励函数表述为:

$$\mathcal{R}_t = \omega_1 \mathcal{R}_t^{\text{sum}} + \omega_2 \mathcal{R}_t^{\text{urllc}} \quad (4-24)$$

其中, ω_1 和 ω_2 为权重系数, 用于平衡多目标优化中的不同性能指标。依据 URLLC 场景对可靠性的严格要求, 权重系数典型设置为 $\omega_1 = 0.6$, $\omega_2 = 0.4$, 在优先保障系统容量的前提下兼顾 URLLC 约束。

4.3.6 算法训练流程

所提 GNN-DRL 融合算法的训练流程如算法3所示, 采用交替优化策略: GNN 负责图结构特征提取, DRL 负责功率控制决策, 两者端到端联合训练。算法主要超参数设置如表4-1所示。

表 4-1 算法超参数设置

参数名称	参数值
GNN 消息传递层数 L	2
GNN 隐藏层维度 D	64
注意力头数 H	4
Actor 网络学习率 α_θ	10^{-4}
Critic 网络学习率 α_ϕ	10^{-3}
折扣因子 γ	0.99
PPO 裁剪参数 ϵ	0.2
经验池容量	10^4
批量大小 B	64
训练回合数 N_{ep}	1000
每回合时隙数 T	100
熵系数 β	0.01

4.3.7 算法复杂度分析

所提算法的计算复杂度主要由图神经网络特征提取和深度强化学习决策两部分构成。

在图神经网络特征提取阶段, 设用户数为 K , 平均邻居数为 $\bar{d}$, 隐藏层维度为 D , 消息传递层数为 L 。每层图注意力网络包含三个计算步骤: 首先是线性变换, 将节点特征映射到新的特征空间, 复杂度为 $\mathcal{O}(KD^2)$; 其次是边增强注意力计算, 利用边特征计算注意力系数, 复杂度为 $\mathcal{O}(K\bar{d}D)$; 最后是特征聚合, 根据注意力权重对邻居特征进行加权求和, 复杂度为 $\mathcal{O}(K\bar{d}D)$ 。因此, 图神经网络单次前向传播的计算复杂度为:

$$\mathcal{O}_{\text{GNN}} = \mathcal{O}(L \cdot K \cdot \bar{d} \cdot D^2) \quad (4-25)$$

Algorithm 3 基于 GNN-DRL 的 CF-mMIMO 功率控制算法

Require: 训练回合数 N_{ep} , 每回合时隙数 T , Actor 学习率 α_θ , Critic 学习率 α_ϕ , 折扣因子 γ , PPO 裁剪参数 ϵ

Ensure: 收敛的策略网络参数 θ 与值网络参数 ϕ

```

1: 随机初始化 GNN 参数  $\Theta_{\text{GNN}}$ , Actor 参数  $\theta$ , Critic 参数  $\phi$ 
2: for  $n = 1$  to  $N_{\text{ep}}$  do
3:   for  $t = 1$  to  $T$  do
4:     基于信道状态构建节点特征  $\{\mathbf{f}_k\}_{k=1}^K$  与边特征  $\{\mathbf{e}_{ik}\}$ 
5:     执行  $L$  层 GNN 消息传递, 输出图嵌入  $\mathbf{z}_k = \text{GNN}(\mathbf{f}_k, \{\mathbf{e}_{ik}\})$ 
6:     构建系统状态  $\mathbf{s}_t = [\mathbf{z}_1, \dots, \mathbf{z}_K, \mathbf{c}]$ , Actor 采样动作  $\mathbf{a}_t \sim \pi_\theta(\cdot | \mathbf{s}_t)$ 
7:     执行功率控制  $\eta_k = \delta_k \cdot \eta_{\text{max}}$ , 观测即时奖励  $\mathcal{R}_t = \omega_1 \mathcal{R}_t^{\text{sum}} + \omega_2 \mathcal{R}_t^{\text{urllc}}$ 
8:     存储转移样本  $(\mathbf{s}_t, \mathbf{a}_t, \mathcal{R}_t, \mathbf{s}_{t+1})$  至经验回放池  $\mathcal{D}$ 
9:   end for
10:  从  $\mathcal{D}$  随机采样批量样本, 计算折扣累积奖励  $G_t = \sum_{l=0}^{\infty} \gamma^l \mathcal{R}_{t+l}$ 
11:  估计优势函数  $A_t = G_t - V_\phi(\mathbf{s}_t)$ , 计算 PPO-Clip 目标函数  $L^{\text{CLIP}}(\theta)$ 
12:  梯度上升更新 Actor:  $\theta \leftarrow \theta + \alpha_\theta \nabla_\theta L^{\text{CLIP}}(\theta)$ 
13:  梯度下降更新 Critic:  $\phi \leftarrow \phi - \alpha_\phi \nabla_\phi (V_\phi(\mathbf{s}_t) - G_t)^2$ 
14:  反向传播端到端联合优化 GNN 参数  $\Theta_{\text{GNN}}$ 
15: end for

```

由于采用稀疏图结构 ($\bar{d} \ll K$), 该复杂度远低于全连接网络的 $\mathcal{O}(K^2 D^2)$, 能够有效控制计算开销。

在深度强化学习决策阶段, Actor 网络和 Critic 网络均为多层感知机结构。设网络层数为 L_{mlp} , 各层维度为 $\{D_l\}_{l=1}^{L_{\text{mlp}}}$, 则深度强化学习部分的计算复杂度为:

$$\mathcal{O}_{\text{DRL}} = \mathcal{O} \left(\sum_{l=1}^{L_{\text{mlp}}-1} D_l \cdot D_{l+1} \right) = \mathcal{O}(K \cdot D^2) \quad (4-26)$$

该复杂度与用户数 K 呈线性关系, 保证了大规模场景下的可扩展性。

综合上述分析, 单时隙决策的总计算复杂度为 $\mathcal{O}(L \cdot K \cdot \bar{d} \cdot D^2 + K \cdot D^2)$, 呈线性于用户数的规模。与传统集中式优化算法相比, 所提算法具有显著优势: 内点法求解非凸功率控制问题的复杂度为 $\mathcal{O}(K^{3.5})$, 且需要多次迭代才能收敛; 穷举搜索法的复杂度为 $\mathcal{O}(2^K)$, 随用户数指数增长。所提算法在推理阶段仅需前向传播, 单次决策复杂度为 $\mathcal{O}(K^2)$, 且可并行加速, 在大规模用户场景下具有显著的计算效率优势, 能够满足超可靠低时延通信的毫秒级时延要求。

4.4 仿真结果

4.5 本章小结

第五章 标题标题标题标题标题标题

第五章内容第五章内容第五章内容第五章内容第五章内容

5.1 标题 1

5.2 标题 2

5.3 标题 3

5.4 本章小结

第六章 总结与展望

6.1 主要研究结论

本论文的主要创新点分别为以下三个方面：

- 1、*****
- 2、*****
- 3、*****

6.2 不足与展望

- 1、*****
- 2、*****
- 3、*****

参考文献

- [1] K. Samdanis and T. Taleb, “The road beyond 5G: A vision and insight of the key technologies,” *IEEE Netw.*, vol. 34, no. 2, pp. 135-141, Feb. 2020.
- [2] V. Ziegler, H. Viswanathan, H. Flinck, M. Hoffmann, V. Räsänen, and K. Hätönen, “6G architecture to connect the worlds,” *IEEE Access*, vol. 8, pp. 173508-173520, Sept. 2020.
- [3] H. Q. Ngo, A. Ashikhmin, H. Yang, E. G. Larsson, and T. L. Marzetta, “Cell-free massive MIMO versus small cells,” *IEEE Trans. Wireless Commun.*, vol. 16, no. 3, pp. 1834-1850, Mar. 2017.
- [4] O. T. Demir, E. Björnson, and L. Sanguinetti, “Foundations of usercentric cell-free massive MIMO,” *Found. Trends Signal Process.*, vol. 14, no. 3-4, pp. 162-472, 2021.
- [5] G. Interdonato, E. Björnson, H. Q. Ngo, P. Frenger, and E. G. Larsson, “Ubiquitous cell-free massive MIMO communications,” *EURASIP J. Wireless Commun. Netw.*, vol. 2019, no. 1, pp. 1-13, Dec. 2019.
- [6] S. -N. Jin, D. -W. Yue, and H. H. Nguyen, “Spectral and energy efficiency in cell-free massive MIMO systems over correlated Rician fading,” *IEEE Syst. J.*, vol. 15, no. 2, pp. 2822-2833, Jun. 2021.
- [7] H. Q. Ngo, L. -N. Tran, T. Q. Duong, M. Matthaiou, and E. G. Larsson, “On the total energy efficiency of cell-free massive MIMO,” *IEEE Trans. Green Commun. Netw.*, vol. 2, no. 1, pp. 25-39, Mar. 2018.
- [8] E. Nayebi, A. Ashikhmin, T. L. Marzetta, H. Yang, and B. D. Rao, “Precoding and power optimization in cell-free massive MIMO systems,” *IEEE Trans. Wireless Commun.*, vol. 16, no. 7, pp. 4445-4459, Jul. 2017.
- [9] L. D. Nguyen, T. Q. Duong, H. Q. Ngo, and K. Tourki, “Energy efficiency in cell-free massive MIMO with zero-forcing precoding design,” *IEEE Commun. Lett.*, vol. 21, no. 8, pp. 1871-1874, Aug. 2017.
- [10] Y. Zhang, M. Zhou, Y. Cheng, L. Yang, and H. Zhu, “RF impairments and low-resolution ADCs for nonideal uplink cell-free massive MIMO systems,” *IEEE Syst. J.*, vol. 15, no. 2, pp. 2519-2530, Jun. 2021.
- [11] S. Chen, J. Zhang, J. Zhang, E. Björnson, and B. Ai, “A survey on user-centric cell-free massive MIMO systems,” 2021, *arXiv:2104.13667*. [Online]. Available: <http://arxiv.org/abs/2104.13667>.
- [12] J. Choi and B. L. Evans, “Analysis of ergodic rate for transmit antenna selection in low-resolution ADC systems,” *IEEE Trans. Veh. Technol.*, vol. 68, no. 1, pp. 952-956, Jan. 2019.
- [13] H. He, C. -K. Wen, and S. Jin, “Bayesian optimal data detector for hybrid mmWave MIMO-OFDM systems with low-resolution ADCs,” *IEEE J. Sel. Topics Signal Process.*, vol. 12, no. 3, pp. 469-483, Jun. 2018.
- [14] S. -N. Hong, S. Kim, and N. Lee, “A weighted minimum distance decoding for uplink multiuser MIMO

- systems with low-resolution ADCs,” *IEEE Trans. Commun.*, vol. 66, no. 5, pp. 1912-1924, May 2018.
- [15] J. Zhang, Y. Wei, E. Björnson, Y. Han, and S. Jin, “Performance analysis and power control of cell-free massive MIMO systems with hardware impairments,” *IEEE Access*, vol. 6, pp. 55302-55314, Sept. 2018.
- [16] M. Xie, X. Yu, Y. Rui, K. Wang, X. Dang, and J. Zhang, “Performance analysis for user-centric cell-free massive MIMO systems with hardware impairments, and multi-antenna users,” *IEEE Trans. Wireless Commun.*, vol. 23, no. 2, pp. 1243-1259, Feb. 2024.
- [17] B. Lim, W. J. Yun, J. Kim, and Y. -C. Ko, “Joint pilot design and channel estimation using deep residual learning for multi-cell massive MIMO under hardware impairments,” *IEEE Trans. Veh. Technol.*, vol. 71, no. 7, pp. 7599-7612, Jul. 2022.
- [18] Y. Zhang, Q. Zhang, H. Hu, L. Yang, and H. Zhu, “Cell-free massive MIMO systems with non-ideal hardware: Phase drifts and distortion noise,” *IEEE Trans. Veh. Technol.*, vol. 70, no. 11, pp. 11604-11618, Nov. 2021.
- [19] S. Jacobsson, U. Gustavsson, G. Durisi, and C. Studer, “Massive MU-MIMO-OFDM uplink with hardware impairments: Modeling and analysis,” in *Proc. Asilomar Conf. Signals, Syst. Comput. (ACSSC)*, Pacific Grove, CA, USA, 2018, pp. 1829-1835.
- [20] E. Björnson, J. Hoydis, M. Kountouris, and M. Debbah, “Massive MIMO systems with non-ideal hardware: Energy efficiency, estimation, and capacity limits,” *IEEE Trans. Inf. Theory*, vol. 60, no. 11, pp. 7112-7139, Nov. 2014.
- [21] E. Björnson, J. Hoydis, and L. Sanguinetti, “Massive MIMO networks: Spectral, energy, and hardware efficiency,” *Found. Trends Signal Process.*, 2017.
- [22] Q. Sun, X. Ji, Z. Wang, X. Chen, Y. Yang, J. Zhang, and K. Wong, “Uplink performance of hardware-impaired cell-free massive MIMO with multi-antenna users and superimposed pilots,” *IEEE Trans. Commun.*, vol. 71, no. 11, pp. 6711-6726, Nov. 2023.
- [23] X. Hu, C. Zhong, X. Chen, W. Xu, H. Lin, and Z. Zhang, “Cell-free massive MIMO systems with low resolution ADCs,” *IEEE Trans. Commun.*, vol. 67, no. 10, pp. 6844-6857, Oct. 2019.
- [24] Y. Zhang, M. Zhou, X. Qiao, H. Cao, and L. Yang, “On the performance of cell-free massive MIMO with low-resolution ADCs,” *IEEE Access*, vol. 7, pp. 117968-117977, Aug. 2019.
- [25] M. Zhou, L. Yang, and H. Zhu, “Sum-SE for multigroup multicast cell-free massive MIMO with multi-antenna users and low-resolution DACs,” *IEEE Wireless Commun. Lett.*, vol. 10, no. 8, pp. 1702-1706, Aug. 2021.
- [26] M. Zhou, J. Li, M. Xie, C. Zhang, and J. Yuan, “Average sum rate of D2D underlaid multigroup multicast cell-free massive MIMO with multi-antenna users,” *IEEE Wireless Commun. Lett.*, vol. 12,

- no. 1, pp. 60-64, Jan. 2023.
- [27] R. S. Sutton and A. G. Barto, *Reinforcement learning: An introduction*. Cambridge, MA, USA: MIT Press, 2018.
- [28] F. Meng, P. Chen, L. Wu, and J. Cheng, "Power allocation in multi-user cellular networks: Deep reinforcement learning approaches," *IEEE Trans. Wireless Commun.*, vol. 19, no. 10, pp. 6255-6267, Oct. 2020.
- [29] Y. Zhao, F. Zhang, Z. Zhou, and G. Hu, "A dynamic power allocation approach for downlink cell-free massive MIMO with graph neural network," *IEEE Trans. Veh. Technol.*, doi: 10.1109/TVT.2024.
- [30] Z. Liu, J. Zhang, E. Shi, Z. Liu, D. Niyato, B. Ai, and X. S. Shen, "Graph neural network meets multi-agent reinforcement learning: Fundamentals, applications, and future directions," *IEEE Wireless Commun.*, vol. 31, no. 6, pp. 39-47, Dec. 2024.
- [31] Y. Shen, J. Zhang, S. H. Song, and K. B. Letaief, "Graph neural networks for wireless communications: From theory to practice," *IEEE Trans. Wireless Commun.*, vol. 22, no. 5, pp. 3554-3569, May 2023.
- [32] U. Gustavsson, C. Sánchez-Perez, T. Eriksson, F. Athley, G. Durisi, and P. Landin, "On the impact of hardware impairments on massive MIMO," in *Proc. IEEE Globecom Workshops (GC Wkshps)*, Austin, TX, USA, 2014, pp. 294-300.
- [33] A. Mohammadi and F. M. Ghannouchi, *RF transceiver design for MIMO wireless communications*. Springer Science & Business Media, 2012, vol. 145.
- [34] D. Rönnow and P. Händel, "Nonlinear distortion noise and linear attenuation in MIMO systems—Theory and application to multiband transmitters," *IEEE Trans. Signal Process.*, vol. 67, no. 20, pp. 5203-5212, Oct. 2019.
- [35] P. Händel and D. Rönnow, "Dirty MIMO transmitters: Does it matter?" *IEEE Trans. Wireless Commun.*, vol. 17, no. 8, pp. 5425-5436, Aug. 2018.
- [36] Ö. T. Demir and E. Björnson, "Channel estimation in massive MIMO under hardware non-linearities: Bayesian methods versus deep learning," *IEEE Open J. Commun. Soc.*, vol. 1, pp. 109-124, Dec. 2020.
- [37] M. Jadidi, A. M. Khoueini, A. Mohammadi, and V. Meghdadi, "Performance analysis and power allocation for uplink cell-free massive MIMO system with nonlinear power amplifier," *IEEE Trans. Commun.*, vol. 72, no. 9, pp. 5473-5485, Sept. 2024.
- [38] J. Zhang, L. Dai, S. Sun, and Z. Wang, "On the spectral efficiency of massive MIMO systems with low-resolution ADCs," *IEEE Commun. Lett.*, vol. 20, no. 5, pp. 842-845, May 2016.
- [39] J. Zhang, L. Dai, Z. He, S. Jin, and X. Li, "Performance analysis of mixed-ADC massive MIMO systems over rician fading channels," *IEEE J. Sel. Areas Commun.*, vol. 35, no. 6, pp. 1327-1338, Jun. 2017.

- [40] J. Yuan, S. Jin, C. -K. Wen, and K. -K. Wong, “The distributed MIMO scenario: Can ideal ADCs be replaced by low-resolution ADCs?,” *IEEE Wireless Commun. Lett.*, vol. 6, no. 4, pp. 470-473, Aug. 2017.
- [41] S. Mishra, L. Salaun, H. Yang, and C. S. Chen, “Graph neural network aided power control in partially connected cell-free massive MIMO,” *IEEE Trans. Wireless Commun.*, vol. 23, no. 9, pp. 12412-12423, Sept. 2024.
- [42] Z. Liu, J. Zhang, Y. Zhu, E. Shi, and B. Ai, “Mobile cell-free massive MIMO with multi-agent reinforcement learning: A scalable framework,” *IEEE Trans. Wireless Commun.*, doi: 10.1109/TWC.2024.
- [43] P. Velickovic, G. Cucurull, A. Casanova, A. Romero, P. Lio, and Y. Bengio, “Graph attention networks” , 2018, *arXiv:1710.10903*. [Online]. Available: <https://arxiv.org/abs/1710.10903>.
- [44] M. Eisen and A. Ribeiro, “Optimal wireless resource allocation with random edge graph neural networks,” *IEEE Trans. Signal Process.*, vol. 68, pp. 2977-2991, Apr. 2020.
- [45] H. Moazzen, A. Mohammadi, and M. Majidi, “Performance analysis of linear precoded MU-MIMO-OFDM systems with nonlinear power amplifiers and correlated channel,” *IEEE Trans. Commun.*, vol. 67, no. 10, pp. 6753-6765, Oct. 2019.

致谢

[illegible]

***** 年 ** 月 ** 日

张三三

攻读硕士学位期间发表的学术论文

- [1] Zhang S, Li S, Wang W, et al, “*****,” *****,
*****.
- [2] Zhang S, Li S, Wang W, et al, “*****,” *****,
*****.
- [3] Zhang S, Li S, Wang W, et al, “*****,” *****,
*****.

攻读硕士学位期间参加的科研项目

1. 国家自然科学基金面上项目：“面向 6G 的高性能低成本去蜂窝大规模 MIMO 技术研究”，项目编号：62071246；（参与）
2. 国家自然科学基金面上项目：“边缘物联网中感知数据协作卸载机制研究”，项目编号：62072159；（参与）
3. 国家自然科学基金面上项目：“面向深度神经网络的边缘智能环境构建及关键技术研究”，项目编号：62472147；（参与）
4. 河南省重点研发专项：“基于 AIGC 的高风险地区城市洪水预警与内涝推演关键技术研究及应用”，项目编号：251111210500。（参与）
5. 河南省重点研发与推广专项（软科学）项目：“数字经济赋能河南新质生产力高质量发展：逻辑机理与耦合路径探赜”，项目编号：252400410514。（参与）

独创性声明

本人郑重声明：所呈交的学位论文是我个人在导师指导下进行的研究工作及取得的成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写的研究成果，也不包含为获得河南师范大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

作者签名：_____ 日期：_____

关于论文使用授权的说明

本人完全了解河南师范大学有关保留、使用学位论文的规定，即：有权保留并向国家有关部门或机构送论文的复印件和磁盘，允许论文被查阅和借阅。本人授权河南师范大学可以将学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。（保密的学位论文在解密后适用本授权书）

作者签名：_____ 导师签名：_____ 日期：_____